面向数学公式的专用分词：硬／软 AST 约束与四类泛化实验

肖童仁

Design and Evaluation of Specialized Tokenizers for Mathematical Formulas

研究信息

数学公式分词
抽象语法树
子词词表
跨领域泛化
可逆编码

代码与数据

math-tokenizer-lab

实验规模

56,000 条公式
9 个分词器
11 组划分
8 项评价指标

摘　要

本文在 56,000 条研究级 LaTeX 公式上比较数学专用分词与通用分词。固定训练型模型词表为 1,024，评价标准硬 AST-BPE、AST-v4、Boundary AST 和 Math-atom BPE，并与 Byte BPE、SentencePiece Unigram、Qwen2.5、Llama 3 及 o200k 比较。实验设置全领域新来源、整域留出、分析方程与代数双向迁移、简单到复杂四类测试，共 11 组划分和 99 组模型评价。统一测量 T/B、命令完整性、数字词素完整性、编码速度、Used、Cross、复合 AST 节点对齐率与 Rényi 效率。全领域测试中，Boundary AST 相对 Byte BPE 减少 7.45% 的每字节 token 数，Cmd 为 99.73%；AST-v4 的复合节点对齐率为 73.33%，编码速度为 32.42 MiB/s。硬结构约束、软结构代价与数学词法原子分别形成不同的压缩、对齐和效率表现。全部评价通过逐式可逆性检验，并提供完整划分、逐式记录与五轮审查。

1　研究问题与相关工作

数学公式由控制命令、数字、运算符、变量和层次化参数组构成。通用分词器通常依据文本频率构建子词，而数学专用分词可以额外使用词法原子或语法树信号。本文研究三个问题：在固定 1,024 个 ID 的条件下，数学原子能否提高编码压缩与命令完整性；AST 硬约束与软约束如何改变压缩、结构对齐和速度；这些性质能否迁移到新来源、新领域以及更复杂的公式。

分词器的设计包含基础单位、词表学习和推理分割三个环节。Sennrich 等 [1] 将 BPE 用于开放词表建模；Kudo[2] 提出 Unigram 子词模型，SentencePiece[3] 将原始字符串训练与分词接口统一起来。Müller 和 Vlachos[4] 提出 AST-BPE，按照语法树限制可合并的相邻节点。AST-T5[5] 进一步说明，结构树既可用于分割，也可用于预训练目标。本文将硬约束 AST-BPE 迁移到数学公式，并与保留硬约束的 AST-v4 和采用软代价的 Boundary AST 进行比较。

评价方面，压缩长度、词表分布和结构对齐测量不同性质。Zouhar 等 [6] 用 Rényi 熵衡量词表信道效率；Uzan 等 [7] 区分词表构造与推理算法的作用；Schmidt 等 [8] 和 Lotz 等 [9] 分别从受控预训练和跨规模评价研究压缩以外的分词性质。TokEval[10] 同时覆盖压缩、词表利用率、速度和语法节点对齐。本文保留六项既有指标，增加 Rényi 效率和复合 AST 节点对齐率，形成八项评价。

数学数字的切分还涉及位值和算法对齐。Singh 和 Strouse[11] 以及 NumeroLogic[12] 研究了数字表示与算术任务之间的关系。本文的 Num 专门测量源码连续数字词素是否被切开；与其互补的数学推理与方程求解，将在后续语言模型实验中检验。不同指标各自对应清晰的观测对象，结果按指标分别比较。

2 数学公式数据集

2.1 来源、内容与类别

数据集包含 56,000 条 LaTeX 公式，来自 366 个来源组：283 篇历史 arXiv 论文、11 篇公开仓库论文及 72 个 FunGrim / SymPy 资源模块。每条记录保存公式、来源论文或资源、固定版本、许可、原始位置、变换记录、内容哈希、领域、复杂度和独立 KaTeX 语法跨度。评估使用目录中保存的原字符串，编码与解码均不改变空格、换行或命令拼写。

表 1 语料来源。来源标签与数学领域分别存储。

来源	公式数	版本与来源标签	许可
2020 年前 arXiv 论文	51,229	283 个固定历史论文来源；human	CC BY / CC0
OpenAI 数学仓库	2,810	固定 Git 版本；possible_mixed	Apache-2.0
FunGrim	1,889	固定资源版本；unknown	MIT
SymPy	72	固定资源版本；unknown	BSD
合计	56,000	366 个来源组	逐条记录

来源构建依次进行：获取固定版本源文件，提取数学环境，展开记录中的局部宏，验证公式语法和宏变换前后的渲染一致性，去重，登记来源与许可，完成分类，保存公式和元数据。`human` 依据 2020 年前论文版本及作者信息登记；其余来源分别使用 `possible_mixed` 和 `unknown` 标签。原始公式、宏定义和展开后的评估字符串可以相互追溯。

表 2 领域分布：公式领域与来源论文领域分别计数。

领域	公式领域	论文领域	领域	公式领域	论文领域
分析	20,233	9,723	概率	3,171	3,171
几何与拓扑	9,135	9,185	统计	1,056	1,056
组合	5,563	5,563	逻辑	662	662
代数	4,431	4,431	PDE	356	5,758
数论	4,273	4,273	ODE	46	5,100
数学物理	3,850	3,850	线性代数	13	13
优化	3,211	3,215			

公式领域与论文领域采用两个字段。前者按照公式本身的微分关系和结构分类；后者记录来源论文的学科，用于整域留出。严格 PDE 公式共 356 条，ODE 公式 46 条。结构标签允许一式多类，包括恒等式或界、求和或乘积、积分、矩阵、多行公式、微分关系和方程组。领域划分使用论文领域，因而来自 PDE 论文中的积分或代数表达式仍属于 PDE 来源域。

2.2 复杂度定义与集合隔离

句法复杂度综合公式长度和符号复杂度。令 L 为 LaTeX 词素数、C 为命令种类、D 为嵌套深度、S 为符号种类、O 为运算符数，则

$$\begin{aligned} K(x) = {} & .40\min(L/60,2) + .20\min(C/6,2) \\ & + .15\min(D/3,2) + .15\min(S/18,2) + .10\min(O/12,2). \end{aligned} \tag{1}$$

$K(x) < .65$ 标记为简单，$K(x) \geq .65$ 标记为复杂。目录中简单公式 37,400 条，复杂公式 18,600 条。该分类测量源码句法复杂度。例如，公式 ID`00023ce032027f7126dc1db0` 的 $(L, C, D, S, O) = (38, 4, 2, 14, 5)$，对应 $K = 0.645$，归入简单类。

本轮根据固定随机种子生成新的研究划分，保存每一集合的全部公式 ID。首先在论文或资源模块层面分组，再删除训练、验证与测试之间的模板和 MathML 渲染重复。训练集合优先保留；验证集合删除与训练重复的项；测试集合删除与训练或验证重复的项。三者的公式 ID、来源组、模板哈希及渲染哈希均无交集。

3 比较模型与严格定义

记输入的 UTF-8 字节串为 x，词表为 V，编码结果为 $z = (z_1, \ldots, z_T)$。每个 token 对应原串的连续字节片段，解码为这些片段按序拼接。六个在本数据集上训练的模型均使用恰好 1,024 个 ID，基础字节与预留原子均计入总数。三个通用分词器使用原始官方词表和代码接口。所有模型编码同一批原始公式，不添加 BOS、EOS 或对话模板。

3.1 标准硬 AST-BPE：受语法约束的逐次合并

标准 AST-BPE 遵循 Müller 和 Vlachos[4] 的约束合并原则。本文将 SQL 场景迁移到 LaTeX：叶节点保留源码位置，叶内部以字节表示，训练只统计与语法层次兼容的相邻片段。数学前端支持算术优先级、分式、根式、分组和上下标；其他 LaTeX 结构采用命令与参数的绑定语法树。

设候选 token 区间为 $[a, b)$，参考节点区间为 $[u, v)$。若满足

$$a < u < b < v \quad \text{或} \quad u < a < v < b, \tag{2}$$

两者发生部分跨越。硬约束要求候选区间与所有前端节点均不发生式(2)的关系。训练按合法相邻对的频率选择合并，记录有序合并规则，直至词表达到 1,024。推理从字节出发，依照训练合并顺序执行当前合法的合并。该模型不预留数学命令原子，完整命令通过 BPE 学习。

3.2 AST-v4：数学原子初始化与硬约束最短分割

AST-v4 沿用硬 AST 主线，在训练前从训练公式中选取至多 256 个高频控制命令和非 ASCII 字符作为原子；加上 256 个基础字节后，余下预算用于受 AST 约束的 BPE 合并。原子按训练频率排序，同频时按字节排序。推理在原串上构建词表匹配格，删除跨越前端语法节点或切开已覆盖完整命令的候选边，再求

$$z^* = \arg\min_{z \in \mathcal{Z}_{\text{hard}}(x;V)} |z|. \tag{3}$$

动态规划从右向左计算最少 token 路径。与标准硬 AST-BPE 相比，v4 保留训练期与推理期的硬结构约束，增加数学原子初始化，并用完整词表上的最短路径替代逐次合并推理。原生 C 前端、trie 匹配和动态规划在一次编码调用内完成。

3.3 Math-atom BPE：数学原子上的标准 BPE

Math-atom BPE 首先从训练集选取至多 384 个高频完整控制命令和非 ASCII 字符，与 256 个基础字节构成可逆原子字母表。已登记的完整命令映射成单个基础符号，其内部不允许出现切点；其他输入以字节表示。然后直接使用 Hugging Face 官方 BPE 训练和推理，学习合并到 1,024 个 ID。该方法的数学信号位于基础字母表，BPE 合并本身采用官方实现。

3.4 Boundary AST：共享词表与软结构代价

Boundary AST 与 Math-atom BPE 共享同一训练所得词表。其命令原子约束保持不变，语法树约束改为可累计的软代价。令 $C_{\text{native}}(z, x)$ 为与推理前端语法跨度发生部分跨越的 token 数，$G(x)$ 为非空花括号组的内部内容端点集合，$B(z)$ 为分词边界集合，则

$$z^* = \arg\min_{z \in \mathcal{Z}(x;V)} \left[|z| + .25 C_{\text{native}}(z, x) + .30 |G(x) \setminus B(z)| \right]. \tag{4}$$

实现以 trie 枚举候选 token，累加 token 数与局部结构代价，再以动态规划求最优路径。权重在所有领域和划分中固定。Math-atom BPE 与 Boundary AST 的差异只发生在分割阶段，因此两者可用于分析软结构引导带来的变化。

表 3 比较模型及词表、推理和代码来源。硬 AST-BPE 为公开算法的数学迁移实现。

模型	词表 / 训练约束	推理	实际 ID 空间	来源
Hard AST-BPE	无原子预留；硬合并	训练次序合并	1,024	代码
AST-v4	至多 256 原子；硬合并	硬约束最短路径	1,024	代码
Boundary AST	与 Math-atom 共享词表	软结构最短路径	1,024	代码
Math-atom BPE	至多 384 原子；官方 BPE	官方 BPE	1,024	代码
Byte BPE	官方字节 BPE	官方 BPE	1,024	代码
SP Unigram	EM 与候选子词剪枝	Viterbi	1,024	代码
Qwen2.5	官方固定检查点	官方 HF 接口	151,665	代码
Llama 3	官方固定检查点	Meta 官方代码	128,256	代码
o200k	官方固定编码	官方 tiktoken	200,019	代码

3.5 五个基准分词器

Byte BPE。Hugging Face 官方 BPE 在可逆字节字母表上训练，256 个字节占据词表中的 256 个 ID；训练和推理不使用数学语法信号。Byte BPE 最小合并频率设为 1，Math-atom BPE 设为 2；两者均训练到固定 1,024 容量。**SentencePiece Unigram**。在原始训练字符串上初始化较大候选子词集合，使用 EM 估计子词概率并逐步剪枝，直到目标词表；推理通过 Viterbi 求 $\arg\max_z \prod_t p(z_t)$。本轮采用 identity 归一化、保留原始空白、byte fallback、关闭句首空格与特殊句首句尾 ID；字符覆盖率为 1、单线程训练、输入顺序固定、最大句长 16,384 字节。所有原始字符串使用相同精确保真检查。**Qwen2.5、Llama 3 和 o200k**。分别调用固定官方词表与接口，词表大小为 151,665、128,256 和 200,019。Qwen2.5 对应千问 2.5 系列，Llama 3 对应 Meta Llama 3 系列，o200k 对应 OpenAI 的 o200k 编码系列。官方完整词表与 1,024 词表的训练型模型分别构成两组容量设置。

4 八项评价指标

所有边界均采用原始 UTF-8 字节坐标。完整编码和 token 字节片段逐条验证，精确保真要求为

$$\mathrm{decode}(\mathrm{encode}(x)) = x. \tag{5}$$

同时，token 负载拼接必须精确等于原始字节串。精确保真作为所有结果的共同通过条件。压缩、命令、数字、速度、词表使用与结构对齐分别评价，各项指标采用固定方向和统计定义。

4.1 压缩、完整性与速度

(1) T/B：每字节 token 数，越低越压缩。为使长论文和短来源组等权，首先对每个测试来源组 g 计算其公式总 token 数 T_g 与原始字节数 B_g 之比，再平均：

$$\mathrm{T/B} = \frac{1}{|\mathcal{P}|} \sum_{g \in \mathcal{P}} \frac{T_g}{B_g}. \tag{6}$$

压缩的倒数为每 token 平均表示的字节量；每个公式的原始长度和 token 数同时保存在逐式记录中。

(2) Cmd：命令完整率，越高表示命令内部切点越少。命令由固定词法规则识别为反斜杠加连续 ASCII 字母，或反斜杠加单个非字母字符。设命令跨度集合为 M，内部 token 边界为 B°，则

$$\mathrm{Cmd} = \frac{\sum_{[a,b) \in M} \mathbf{1}[B^\circ \cap (a,b) = \varnothing]}{|M|}. \tag{7}$$

完整命令可以与相邻字符同处一个 token，只要其内部没有切点即计为完整。

(3) Num：数字词素完整率，越高表示连续数字词素内部切点越少。数字由连续十进制数字及可选小数部分组成，匹配规则为

```
[0-9]+(?:\.[0-9]+)?
```

将 Cmd 公式中的 M 替换为数字词素集合，测量源码数字串。

(4) 编码速度：MiB/s，越高越快。令测试输入的原始字节总数为 B，完整 `encode(string)->IDs` 接口的运行时间为 t，则

$$\text{Speed} = \frac{B}{2^{20}t}. \tag{8}$$

计时包含字母表转换、前端解析、词表匹配与实际分割；所有方法采用同样的逐公式调用方式。模型加载与指标计算在计时区间之外。七轮交错顺序编码、每轮清缓存，以时间中位数计算速度。

4.2 词表分布与结构保持

(5) Used：实际使用 ID 占比。设测试集使用过的不同 ID 集合为 V_{used}，报告 $100|V_{\text{used}}|/|V|$。分母使用完整实际 ID 空间，包括基础字节、预留原子和特殊 ID。该值描述词表覆盖与利用情况。

(6) Cross：KaTeX 部分跨越比例，越低表示部分跨越 token 越少。使用数据集的独立 KaTeX 语法跨度 $\mathcal{R}(x)$，按式(2)判断每个 token。分子为至少与一个参考跨度发生部分跨越的 token 数，分母为测试 token 总数。同一 token 跨越多个跨度只计一次。它与推理前端采用不同的参考跨度，所有模型使用同一 KaTeX 标注。

(7) AST-A：复合 AST 节点双端对齐率，越高表示复合节点的起止位置越常保留为 token 边界。借鉴 TokEval 的 AST 节点双端对齐判据 [10]，本文将评价对象扩展为数学公式中的复合语法节点：从 KaTeX 跨度中去掉完整公式根跨度及与单个词法单位完全相同的跨度，去重得到 $\mathcal{R}_c(x)$。定义

$$\text{AST-A} = \frac{\sum_x \sum_{[a,b)\in\mathcal{R}_c(x)} \mathbf{1}[a \in B(z_x) \wedge b \in B(z_x)]}{\sum_x |\mathcal{R}_c(x)|}. \tag{9}$$

节点内部允许使用多个 token；关键是能在 token 序列中精确定位该复合单元的完整区间。Cross 以 token 为分母，AST-A 以复合节点为分母，分别检查部分跨越和完整节点边界。二者与 T/B 一起呈现结构与压缩的关系。

(8) $\eta_{2.5}$：Rényi 词表效率，越高表示 token 概率质量在词表上分配得更均衡。根据测试 token 的经验频率 p_i，采用 Zouhar 等 [6] 和 TokEval 的定义：

$$\eta_{2.5} = \frac{H_{2.5}(p)}{\log_2 |V|}, \qquad H_\alpha(p) = \frac{1}{1-\alpha}\log_2 \sum_i p_i^\alpha. \tag{10}$$

分母采用声明的完整词表大小。Used 只统计一个 ID 是否出现，Rényi 效率还考虑每个 ID 出现多少次。Cognetta 等 [13] 给出的反例表明，分布均匀性与具体任务能力需要分别测量，因此本轮直接报告各项值。

4.3 来自本轮测试集的实例

测试公式 `x>\frac{2}n` 来自 arXiv:1602.08801，ID 为 `0e5a942aa5faafdca707467a`，原串共 11 字节。表4给出三种实际输出。

表 4 同一真实公式的分词及事件计数。竖线表示 token 边界。

模型	实际 token 序列	T/B	Cmd	Cross	AST-A
Boundary AST	`x` | `>` | `\frac{` | `2}` | `n`	5/11	1/1	1/5	0/2
Hard AST-BPE	`x` | `>` | `\frac` | `{2}` | `n`	5/11	1/1	0/5	2/2
Qwen2.5	`x` | `>\` | `frac` | `{` | `2` | `}` | `n`	7/11	0/1	0/7	2/2

Boundary AST 和 Hard AST-BPE 均产生 5 个 token，单式 T/B 为 $5/11 \approx .455$，且`\frac` 内部没有切点，Cmd 均为 100%。软约束模型将分式命令与左花括号合并，跨过复合节点的起点，Cross 为 $1/5 = 20\%$；硬约束模型保留花括号分组的完整边界，Cross 为 0。该式两个复合参考跨度的双端在硬约束输出中全部保留，AST-A 为 100%，软约束输出为 0。Qwen2.5 把反斜杠与 `frac` 分开，Cmd 为 0；其更细分的序列保留了两个复合跨度的双端，AST-A 为 100%。三列分别显示命令内部、部分跨越和复合单元边界三种性质。数字实例为测试公式 `y_{m,n}(1)\geq C_{12}`（ID：`06a371ce545de9ef798775c5`）。Hard AST-BPE 保留 2/2 个数字词素；Boundary AST 保留 1/2 个数字词素。该式的数字词素为 1 和 12，Boundary AST 在 12 内部产生切点，而 Hard AST-BPE 保留完整的 12。第一组全领域测试输入共 659,113 字节，即 0.6286 MiB；Boundary AST 的中位编码时间为 0.02121 秒，速度为 29.63 MiB/s。该组实际使用 696 个 ID，Used 为 67.97%；Rényi 熵为 7.0755 bit，除以 $\log_2 1024 = 10$，得到 $\eta_{2.5} = 0.7075$。例如相同的两个已用 ID，使用次数分别为 50 / 50 与 90 / 10 时，Used 相同，而后者的 Rényi 效率更低；它刻画频率集中度。

5 实验设计与实施

5.1 训练、验证与测试的职责

训练集用于构建数学原子、统计合并频率、构造 BPE 词表或估计 Unigram 子词概率。它决定的不仅是词表中的字符串，还包括 BPE 合并规则或 Unigram 概率。**验证集**与训练来源隔离，用于检查编码接口、查看来源域内的分布与固定参数表现；本轮九个模型的算法、词表大小、原子预算与 Boundary 权重在测试之前固定，按 ID 顺序取至多 256 条验证公式进行共同接口诊断，验证公式不参与词表构造。固定参数实验可以直接采用训练 / 测试两集；保留验证集使后续开发与最终测试继续隔离。**测试集**包含训练和验证集合之外的来源组，并删除模板和渲染重叠，用于评价新公式与分布迁移。

5.2 四类泛化测试

全领域 ID。按来源领域分层，以来源论文或资源模块为最小分组，约 80% 来源组用于训练、10% 用于验证、其余用于测试。使用 17、29、43 三个固定种子。不同来源组的公式数不同，实际公式数量按来源组划分结果计算。**整域 OOD**。设置三组留出领域：几何拓扑 / 组合 / 数论，概率 / 统计 / 优化，分析 / PDE / ODE。留出领域全部用于测试；含任一目标领域记录的来源组从训练候选中整组排除，其他领域的来源组约 90% 训练、10% 验证。**极限 OOD**。以分析 / PDE / ODE 为一个学科族，代数 / 数论 / 线性代数为另一个学科族，进行双向迁移：仅用一个族构建词表，在另一个族测试。**复杂度迁移**。沿用三个 ID 来源组划分，只用训练和验证来源中的简单公式；仅测试留出来源中的复杂公式。

表 5 十一组实际划分。括号为来源组数；每行已清除跨集合的模板及渲染重叠。

类型	设置	训练	验证	测试
全领域新来源	id_17	44,070（291）	4,656（38）	7,022（37）
简单 → 复杂	complexity_17	29,863（286）	3,032（37）	2,769（34）
全领域新来源	id_29	43,262（291）	8,317（38）	4,184（37）
简单 → 复杂	complexity_29	29,119（286）	5,347（38）	1,487（34）
全领域新来源	id_43	44,515（291）	5,516（38）	5,725（37）
简单 → 复杂	complexity_43	29,347（286）	3,768（37）	1,684（33）
整域 OOD	ood_1	31,684（217）	5,214（26）	18,622（123）
整域 OOD	ood_2	42,081（295）	6,357（33）	7,334（38）
整域 OOD	ood_3	31,313（203）	4,022（24）	20,259（139）
极限 OOD	分析方程 → 代数	16,893（124）	3,298（14）	8,576（66）
极限 OOD	代数 → 分析方程	7,707（59）	1,002（6）	20,420（139）

四类测试分别控制来源组、学科、数学表示体系和句法复杂度。ID 已测量未见公式的泛化，整域 OOD 和极限 OOD 进一步引入语料分布变化。各类设置在正文中分开报告；极限 OOD 同时给出两个迁移方向，复杂度迁移同时报告三个来源划分。完整结果按 11 组逐项列于附录。

5.3 共同输入、统计与运行协议

所有训练型模型读取同一训练 ID 列表，顺序固定；预训练模型直接使用公开检查点。测试集不进行模型专属清洗、截断或删样。每组模型处理完全相同的测试字符串，所有 ID 均检查范围，所有输出均验证原始字节保真。指标参考由固定词法规则与 KaTeX 0.16.25 构成，训练型 AST 前端不负责生成评价参考。

每个来源组先汇总 token 与字节数，再计算 T/B；命令、数字、部分跨越与复合节点采用全测试集事件计数；Used 和 Rényi 使用全测试 token 分布。相同实验组以相同来源组抽样索引进行 1,000 次 bootstrap，得到 T/B 及结构 / 完整性指标的 95% 区间。三个 ID 种子及三个复杂度种子表示来源划分变化；它们采用同一算法与容量。整域 OOD 的三个留出组合、极限 OOD 的两个方向表示不同迁移设置。

编码测速采用单进程，模型接口保持逐公式调用。计时前完成模型加载与本机扩展构建；每轮清除结构和 BPE 可清理缓存，九个方法以固定随机交错顺序运行七轮。报告中位时间对应的 MiB/s。运行环境为 macOS-26.5.1-arm64-arm-64bit、arm64、Python 3.11.15；词表训练型基准使用仓库固定的 Hugging Face tokenizers 与 SentencePiece 版本。设备与依赖的完整版本保存在实验协议中。

6 实验结果

正文表格对每个测试设置先计算八项指标，再在同类设置内等权平均。ID 与复杂度各包含三组来源划分，整域 OOD 包含三组留出学科，极限 OOD 包含两个迁移方向。完整单组结果见附录。所有 99 组模型评价均通过原始字节与字符串精确保真检查。

6.1 全领域新来源：压缩、命令与结构的取舍

表 6 全领域新来源测试：三个来源划分的均值。百分比列的单位均为%。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	AST-A ↑	Used	$\eta_{2.5}$ ↑	速度 ↑
Hard AST-BPE	0.4181	92.28	96.87	**7.71**	**74.71**	74.74	62.88	14.81
AST-v4	0.4006	99.01	96.87	8.09	73.33	76.76	62.53	**32.42**
Boundary AST	**0.3799**	**99.73**	96.37	17.50	39.28	67.97	69.69	29.36
Math-atom BPE	0.3830	**99.73**	96.37	18.18	38.23	68.03	70.36	10.00
Byte BPE	0.4105	36.27	96.37	25.17	24.23	78.26	**75.16**	8.49
SP Unigram	0.4783	4.18	97.42	19.80	28.55	71.65	59.96	23.76
Qwen2.5	0.5261	2.02	96.37	19.98	31.51	1.02	32.99	3.15
Llama 3	0.5228	2.02	**99.23**	20.14	29.06	1.30	33.52	9.00
o200k	0.5174	2.62	**99.23**	20.58	27.74	0.81	32.63	14.28

Boundary AST 的 T/B 为 0.3799，相对 Byte BPE 减少 7.45%，相对硬 AST-BPE 减少 9.12%。Math-atom BPE 为 0.3830；两者共享词表后，软结构路径使 T/B 进一步减少 0.80%。Boundary AST 与 Math-atom BPE 的 Cmd 均值分别为 99.73% 与 99.73%，表明数学原子初始化直接改善了完整命令的表示。硬约束的优势体现在结构列：Hard AST-BPE 与 AST-v4 的 AST-A 分别为 74.71% 和 73.33%，Cross 分别为 7.71% 和 8.09%；Boundary AST 的对应值为 39.28% 和 17.50%。因此压缩最优路径与最多复合节点边界是不同目标，硬 / 软约束提供不同工作点。硬约束使用原生算术 / 绑定语法前端，Cross 与 AST-A 使用独立 KaTeX 参考；两个前端生成的语法跨度有差异，表中的 Cross 测量所有模型与同一外部参考

的一致性。Llama 3 与 o200k 的 Num 均值为 99.23% 与 99.23%，Byte BPE 的 Rényi 效率为 75.16%，这些列保留了通用数字分组和字节 BPE 分布性质的优势。

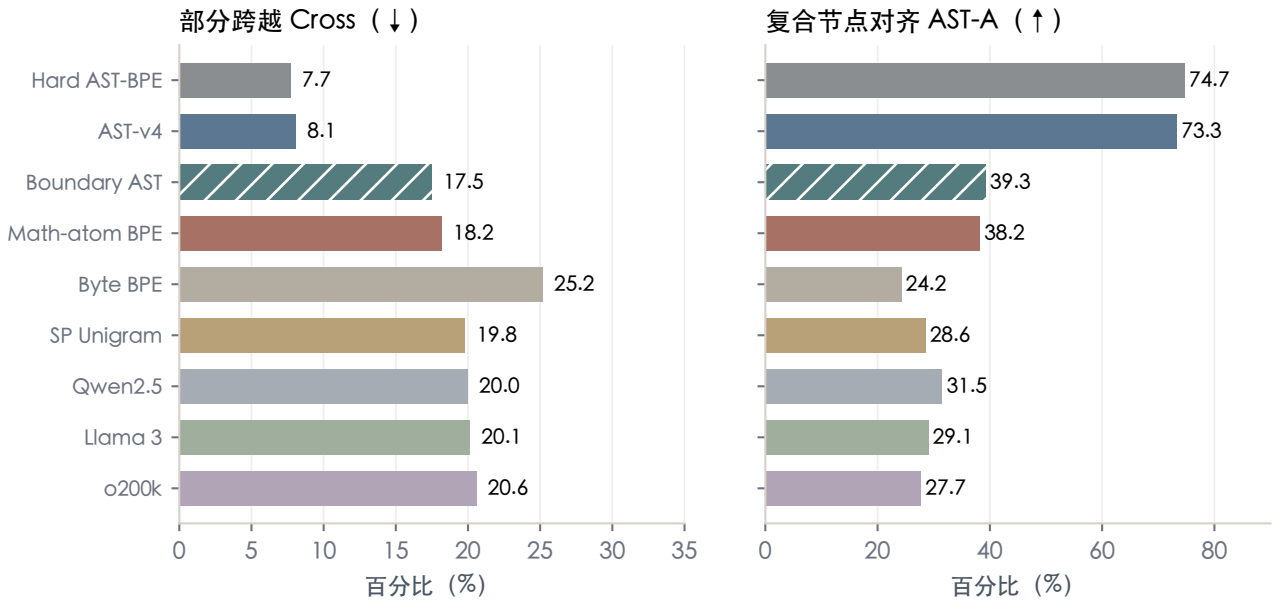


图 1　全领域测试中的两种结构测量。柱形为三个来源划分的均值，数值单位为%。

6.2　整域与极限 OOD：词表的跨学科迁移

表 7　三个整域留出设置的等权均值。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	AST-A ↑	Used	$\eta_{2.5}$ ↑	速度 ↑
Hard AST-BPE	0.4287	91.60	97.54	**7.32**	**76.29**	75.88	61.52	14.67
AST-v4	0.4089	98.90	97.60	7.81	74.69	78.16	61.34	**30.67**
Boundary AST	**0.3869**	**99.70**	97.08	17.26	40.08	71.39	69.31	27.80
Math-atom BPE	0.3908	**99.70**	97.08	17.79	38.81	71.48	69.65	9.39
Byte BPE	0.4161	46.20	97.08	23.47	26.13	79.49	**74.39**	7.73
SP Unigram	0.4890	3.09	97.92	19.49	28.77	72.56	59.76	22.57
Qwen2.5	0.5238	2.10	97.08	19.54	32.22	1.38	33.07	3.17
Llama 3	0.5211	2.10	**99.36**	19.66	30.09	1.90	33.59	8.80
o200k	0.5169	2.52	**99.36**	20.04	28.99	1.19	32.81	14.01

表 8 分析 / 方程与代数 / 数论双向极限 OOD 的均值。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	AST-A ↑	Used	$\eta_{2.5}$ ↑	速度 ↑
Hard AST-BPE	0.4374	87.14	96.10	**7.30**	**78.48**	75.44	60.84	15.10
AST-v4	0.4220	98.27	96.10	7.61	77.80	76.07	59.94	**30.72**
Boundary AST	**0.3919**	**98.58**	95.29	16.59	42.90	74.61	69.38	27.98
Math-atom BPE	0.3967	**98.58**	95.29	16.94	41.79	74.46	69.83	9.56
Byte BPE	0.4286	45.84	95.34	21.52	31.40	77.05	**72.69**	7.71
SP Unigram	0.5019	3.38	96.39	18.80	30.75	71.34	61.26	22.21
Qwen2.5	0.5265	1.95	95.28	19.22	34.52	1.40	33.21	3.13
Llama 3	0.5219	1.95	**99.01**	19.40	30.67	1.98	33.78	8.76
o200k	0.5183	2.54	**99.01**	19.71	29.61	1.25	33.04	14.30

整域 OOD 中，T/B 最小者为 Boundary AST（0.3869）。Boundary AST 的 Cmd 为 99.70%，AST-v4 的 AST-A 为 74.69%。完整留出领域和方向分别列于表5与附录。极限 OOD 中，T/B 最小者为 Boundary AST（0.3919）。Boundary AST 的 Cmd 为 98.58%，AST-v4 的 AST-A 为 77.80%。完整留出领域和方向分别列于表5与附录。

6.3 简单到复杂：长度与层次变化

表 9 简单公式训练、复杂公式测试：三个来源划分均值。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	AST-A ↑	Used	$\eta_{2.5}$ ↑	速度 ↑
Hard AST-BPE	0.4226	86.17	96.91	**7.63**	**74.66**	73.11	61.78	16.38
AST-v4	0.4022	98.81	96.93	8.06	73.25	74.25	61.87	**41.04**
Boundary AST	**0.3802**	**99.62**	96.13	17.96	38.18	67.25	69.29	36.33
Math-atom BPE	0.3852	**99.62**	96.13	19.16	36.13	67.06	69.41	11.88
Byte BPE	0.4084	64.80	96.13	21.50	29.17	76.89	**72.04**	9.56
SP Unigram	0.5020	2.72	97.42	16.00	37.73	67.84	53.34	29.80
Qwen2.5	0.5142	2.73	96.13	20.40	30.86	0.87	32.83	3.47
Llama 3	0.5110	2.73	**99.14**	20.58	28.38	1.09	33.37	10.12
o200k	0.5058	3.29	**99.14**	21.09	26.98	0.68	32.49	16.31

只在简单公式上构建词表后，Boundary AST 在复杂公式上的 T/B 为 0.3802，相对 Byte BPE 减少 6.91%，Cmd 为 99.62%。AST-v4 的 AST-A 为 73.25%，编码速度为 41.04 MiB/s。该设置同时改变未见来源与公式句法复杂度。

6.4 运行速度与词表使用

全领域测试中，AST-v4、Boundary AST、Math-atom BPE 和 Byte BPE 的平均完整编码速度分别为 32.42、29.36、10.00 与 8.49 MiB/s。AST-v4 和 Boundary AST 在 C 前端中融合解析、trie 与路径搜索；速度比较涵盖全部这些步骤。Used 以完整 ID 空间为分母，通用词表与数学专用词表在本公式集上的实际使用比例直接列于各表。

6.5 分指标排序与模型选择

Boundary AST 在 11 个单独设置中均取得最低 T/B。以四类测试分别等权后得到分指标前三名，见表10；数值相同时并列，表格展示顺序沿用模型列表。Used 描述测试集使用词表的比例。压缩、命令和数字完整性、语法对齐、分布均匀性与速度分别报告。

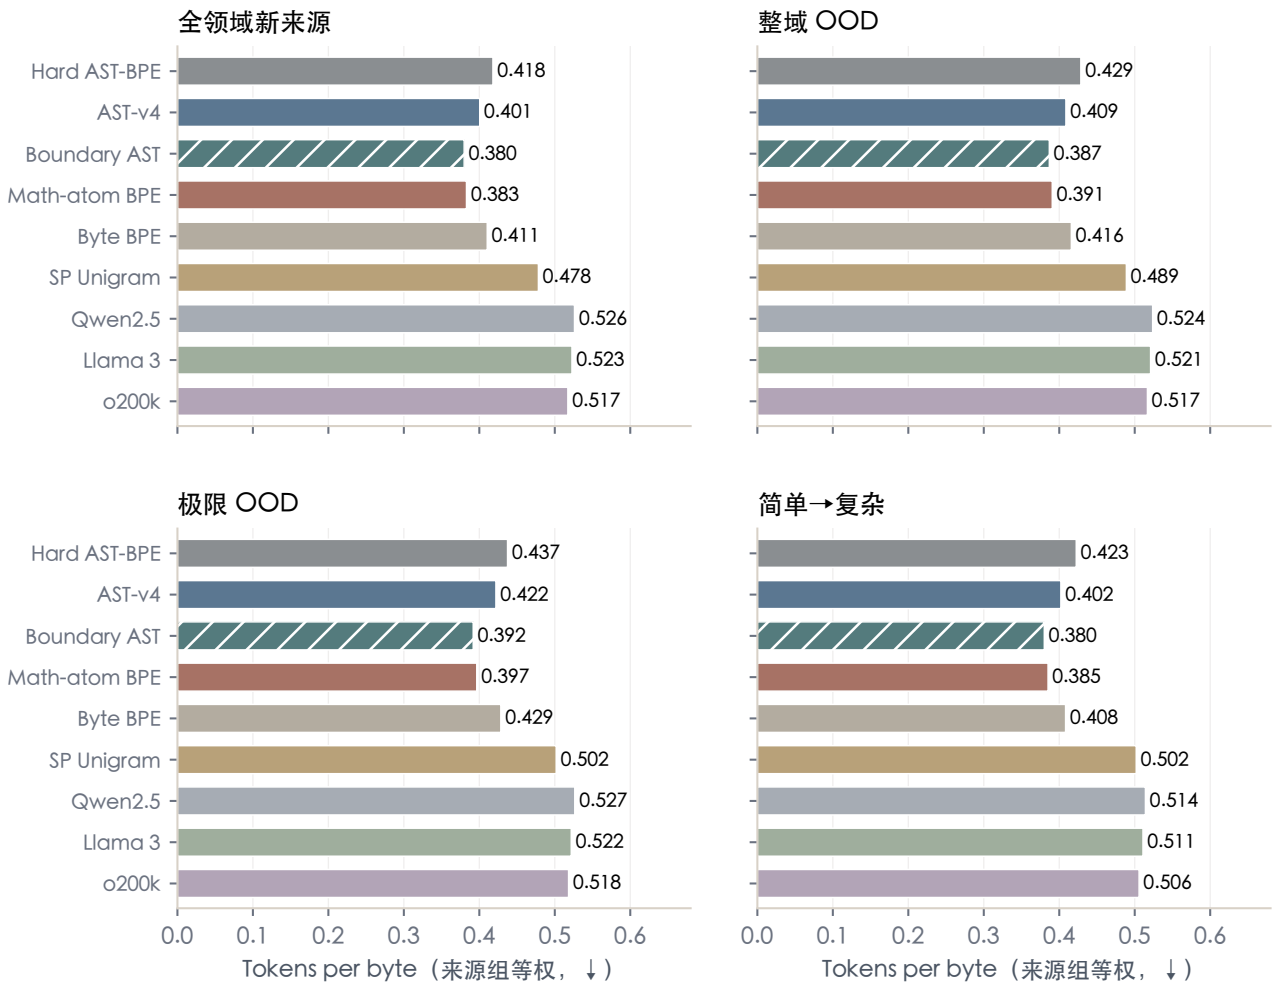


图 2　四类泛化测试的压缩结果。各柱为同类设置等权均值；横轴从零开始，越短表示每字节所需 token 越少。

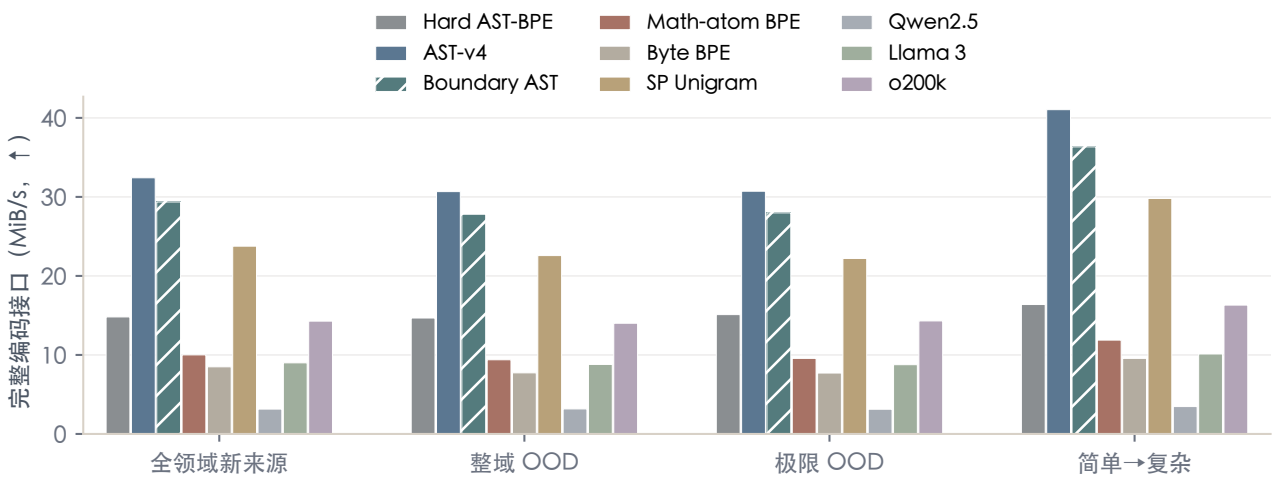


图 3　相同测试输入、逐公式完整接口和七轮交错计时下的编码速度。每类对其设置等权平均。

表 10 四类测试等权后的分指标排序，等值并列。Used 不用于质量排序。

指标	第一梯队	第二梯队	第三梯队
T/B	Boundary AST 0.3847	Math-atom BPE 0.3889	AST-v4 0.4084
Cmd	Boundary AST / Math-atom BPE 99.41%	AST-v4 98.75%	Hard AST-BPE 89.30%
Num	Llama 3 / o200k 99.19%	SP Unigram 97.28%	AST-v4 96.87%
Cross	Hard AST-BPE 7.49%	AST-v4 7.89%	Boundary AST 17.33%
AST-A	Hard AST-BPE 76.04%	AST-v4 74.77%	Boundary AST 40.11%
$\eta_{2.5}$	Byte BPE 73.57%	Math-atom BPE 69.81%	Boundary AST 69.42%
速度	AST-v4 33.71	Boundary AST 30.37	SP Unigram 24.59

下游实验保留软约束 Boundary AST 与硬约束 AST-v4 两个结构工作点，以 Math-atom BPE 分离词表与分割贡献，并保留 Byte BPE、SP Unigram 及三个通用词表作为参照。标准硬 AST-BPE 给出不预留数学原子的硬结构基线。

7 结论与后续实验

固定 1,024 词表的实验显示，数学原子能够提高完整命令的表示，结构信号决定压缩与复合节点边界之间的工作点。Boundary AST 在全领域新来源测试中取得 0.3799 的 T/B，AST-v4 取得 73.33% 的复合节点对齐率和 32.42 MiB/s 的完整编码速度。四类划分将来源泛化、学科迁移与复杂度迁移分开测量，八项指标从压缩、词表使用、结构和运行效率描述各模型。下一阶段将采用相同模型架构、训练字节量和计算预算，从零训练接入不同分词器的模型，评价 PDE / ODE 求解、符号求导与积分、非方程类数学推理；同时比较训练吞吐、总训练计算量与任务准确率。

参考文献

[1] Rico Sennrich, Barry Haddow, and Alexandra Birch. Neural machine translation of rare words with subword units. In Katrin Erk and Noah A. Smith, editors, *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 1715–1725, Berlin, Germany, August 2016. Association for Computational Linguistics. doi: 10.18653/v1/P16-1162. URL https://aclanthology.org/P16-1162/.

[2] Taku Kudo. Subword regularization: Improving neural network translation models with multiple subword candidates. In Iryna Gurevych and Yusuke Miyao, editors, *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 66–75, Melbourne, Australia, July 2018. Association for Computational Linguistics. doi: 10.18653/v1/P18-1007. URL https://aclanthology.org/P18-1007/.

[3] Taku Kudo and John Richardson. SentencePiece: A simple and language independent subword tokenizer and detokenizer for neural text processing. In Eduardo Blanco and Wei Lu, editors, *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pages 66–71, Brussels, Belgium, November 2018. Association for Computational Linguistics. doi: 10.18653/v1/D18-2012. URL https://aclanthology.org/D18-2012/.

[4] Samuel Müller and Andreas Vlachos. Byte-pair encoding for text-to-sql generation. *arXiv preprint arXiv:1910.08962*, 2019. URL https://arxiv.org/abs/1910.08962.

[5] Linyuan Gong, Mostafa Elhoushi, and Alvin Cheung. AST-t5: Structure-aware pretraining for code generation and understanding. In *Proceedings of the 41st International Conference on Machine Learn-*

ing, volume 235, pages 15839–15853. PMLR, 2024. URL https://proceedings.mlr.press/v235/gong24c.html.

[6] Vilém Zouhar, Clara Meister, Juan Gastaldi, Li Du, Mrinmaya Sachan, and Ryan Cotterell. Tokenization and the noiseless channel. In Anna Rogers, Jordan Boyd-Graber, and Naoaki Okazaki, editors, *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 5184–5207, Toronto, Canada, July 2023. Association for Computational Linguistics. doi: 10.18653/v1/2023.acl-long.284. URL https://aclanthology.org/2023.acl-long.284/.

[7] Omri Uzan, Craig W. Schmidt, Chris Tanner, and Yuval Pinter. Greed is all you need: An evaluation of tokenizer inference methods. In Lun-Wei Ku, Andre Martins, and Vivek Srikumar, editors, *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, pages 813–822, Bangkok, Thailand, August 2024. Association for Computational Linguistics. doi: 10.18653/v1/2024.acl-short.73. URL https://aclanthology.org/2024.acl-short.73/.

[8] Craig W Schmidt, Varshini Reddy, Haoran Zhang, Alec Alameddine, Omri Uzan, Yuval Pinter, and Chris Tanner. Tokenization is more than compression. In Yaser Al-Onaizan, Mohit Bansal, and Yun-Nung Chen, editors, *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, pages 678–702, Miami, Florida, USA, November 2024. Association for Computational Linguistics. doi: 10.18653/v1/2024.emnlp-main.40. URL https://aclanthology.org/2024.emnlp-main.40/.

[9] Jonas F. Lotz, António V. Lopes, Stephan Peitz, Hendra Setiawan, and Leonardo Emili. Beyond text compression: Evaluating tokenizers across scales. In Wanxiang Che, Joyce Nabende, Ekaterina Shutova, and Mohammad Taher Pilehvar, editors, *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 32155–32173, Vienna, Austria, July 2025. Association for Computational Linguistics. ISBN 979-8-89176-251-0. doi: 10.18653/v1/2025.acl-long.1546. URL https://aclanthology.org/2025.acl-long.1546/.

[10] Clara Meister. TokEval: A tokenizer evaluation suite. *arXiv preprint arXiv:2608.18062*, 2026. URL https://arxiv.org/abs/2608.18062.

[11] Aaditya K. Singh and DJ Strouse. Tokenization counts: the impact of tokenization on arithmetic in frontier LLMs. *arXiv preprint arXiv:2402.14903*, 2024. URL https://arxiv.org/abs/2402.14903.

[12] Eli Schwartz, Leshem Choshen, Joseph Shtok, Sivan Doveh, Leonid Karlinsky, and Assaf Arbelle. NumeroLogic: Number encoding for enhanced LLMs' numerical reasoning. In Yaser Al-Onaizan, Mohit Bansal, and Yun-Nung Chen, editors, *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, pages 206–212, Miami, Florida, USA, November 2024. Association for Computational Linguistics. doi: 10.18653/v1/2024.emnlp-main.12. URL https://aclanthology.org/2024.emnlp-main.12/.

[13] Marco Cognetta, Vilém Zouhar, Sangwhan Moon, and Naoaki Okazaki. Two counterexamples to tokenization and the noiseless channel. In Nicoletta Calzolari, Min-Yen Kan, Veronique Hoste, Alessandro Lenci, Sakriani Sakti, and Nianwen Xue, editors, *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, pages 16897–16906, Torino, Italia, May 2024. ELRA and ICCL. URL https://aclanthology.org/2024.lrec-main.1469/.

A 各组划分的完整结果

所有表格采用同一列顺序和相同统计口径。T/B 为来源组等权平均；Cmd、Num、Cross、AST-A、Used 和 $\eta_{2.5}$ 均以百分数表示；速度单位为 MiB/s。每组测试公式完全相同。表中同时列出六个 1,024 词表模型与三个使用官方完整词表的通用模型。

表 11 id_17：训练 44,070、验证 4,656、测试 7,022 条公式。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	AST-A ↑	Used	$\eta_{2.5}$ ↑	速度 ↑
Hard AST-BPE	0.4253	92.92	98.14	**8.32**	**73.77**	75.00	62.82	14.77
AST-v4	0.4094	99.07	98.14	8.61	72.66	76.27	62.27	**32.99**
Boundary AST	**0.3829**	**99.92**	97.63	18.85	37.08	67.97	70.75	29.63
Math-atom BPE	0.3860	**99.92**	97.63	19.87	35.45	68.16	71.12	10.34
Byte BPE	0.4152	38.04	97.63	26.31	22.16	78.71	**75.08**	8.59
SP Unigram	0.4827	4.16	98.38	20.32	27.13	71.00	59.99	25.26
Qwen2.5	0.5360	2.54	97.63	20.70	29.06	1.04	32.63	3.17
Llama 3	0.5320	2.54	**98.67**	20.81	28.07	1.31	33.14	9.05
o200k	0.5257	2.92	**98.67**	21.24	26.39	0.81	32.54	14.19

表 12 complexity_17：训练 29,863、验证 3,032、测试 2,769 条公式。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	AST-A ↑	Used	$\eta_{2.5}$ ↑	速度 ↑
Hard AST-BPE	0.4223	83.58	98.04	**7.82**	**74.06**	74.71	61.99	16.26
AST-v4	0.4001	99.09	98.11	8.42	72.76	75.29	62.04	**39.21**
Boundary AST	**0.3768**	**99.86**	97.36	18.46	37.00	67.77	70.16	34.97
Math-atom BPE	0.3822	**99.86**	97.36	20.53	33.82	67.68	69.66	11.65
Byte BPE	0.4059	67.29	97.36	21.61	28.11	78.22	**71.65**	9.44
SP Unigram	0.5009	1.60	98.26	15.58	36.21	68.16	53.37	28.89
Qwen2.5	0.5219	3.27	97.36	20.90	28.64	0.90	32.51	3.43
Llama 3	0.5190	3.27	**98.45**	20.99	27.71	1.13	33.03	10.06
o200k	0.5123	3.68	**98.45**	21.51	25.88	0.70	32.43	16.03

表 13 id_29：训练 43,262、验证 8,317、测试 4,184 条公式。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	AST-A ↑	Used	$\eta_{2.5}$ ↑	速度 ↑
Hard AST-BPE	0.4220	91.85	95.77	**7.05**	**75.47**	74.22	63.46	15.11
AST-v4	0.4027	98.70	95.77	7.46	74.14	76.27	63.32	**33.97**
Boundary AST	**0.3861**	**99.37**	95.43	17.57	38.26	66.80	70.28	29.70
Math-atom BPE	0.3894	**99.37**	95.43	18.23	37.39	66.99	70.87	10.02
Byte BPE	0.4138	38.62	95.43	25.58	23.88	76.95	**75.50**	8.75
SP Unigram	0.4782	3.87	96.53	20.15	27.87	71.29	60.08	23.56
Qwen2.5	0.5304	2.02	95.43	20.19	31.72	0.89	33.29	3.12
Llama 3	0.5257	2.02	**99.33**	20.43	27.80	1.17	33.84	9.00
o200k	0.5206	2.36	**99.33**	20.96	26.06	0.74	32.59	14.59

表 14 complexity_29：训练 29,119、验证 5,347、测试 1,487 条公式。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	AST-A ↑	Used	$\eta_{2.5}$ ↑	速度 ↑
Hard AST-BPE	0.4333	84.70	95.23	**6.97**	**75.84**	71.19	62.02	16.71
AST-v4	0.4072	98.54	95.23	7.53	74.05	72.85	62.38	**41.79**
Boundary AST	**0.3868**	**99.20**	94.42	18.35	36.59	65.62	69.09	36.95
Math-atom BPE	0.3915	**99.20**	94.42	19.31	35.61	65.23	69.29	12.12
Byte BPE	0.4208	55.01	94.42	22.79	26.48	75.00	**71.80**	9.81
SP Unigram	0.5096	2.50	96.11	15.85	39.47	67.29	52.42	29.88
Qwen2.5	0.5192	2.78	94.42	20.57	31.77	0.75	33.00	3.42
Llama 3	0.5136	2.78	**99.20**	20.86	27.28	0.97	33.57	10.05
o200k	0.5097	2.83	**99.20**	21.45	25.49	0.61	32.38	16.30

表 15 id_43：训练 44,515、验证 5,516、测试 5,725 条公式。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	AST-A ↑	Used	$\eta_{2.5}$ ↑	速度 ↑
Hard AST-BPE	0.4069	92.07	96.71	**7.75**	**74.88**	75.00	62.36	14.54
AST-v4	0.3897	99.27	96.71	8.19	73.20	77.73	62.00	**30.30**
Boundary AST	**0.3709**	**99.92**	96.06	16.07	42.50	69.14	68.02	28.74
Math-atom BPE	0.3737	**99.92**	96.06	16.44	41.85	68.95	69.09	9.65
Byte BPE	0.4027	32.14	96.06	23.62	26.65	79.10	**74.92**	8.15
SP Unigram	0.4741	4.52	97.34	18.93	30.66	72.66	59.79	22.47
Qwen2.5	0.5120	1.51	96.06	19.05	33.74	1.13	33.04	3.15
Llama 3	0.5106	1.51	**99.70**	19.19	31.30	1.41	33.57	8.94
o200k	0.5057	2.56	**99.70**	19.53	30.78	0.87	32.76	14.05

表 16 complexity_43：训练 29,347、验证 3,768、测试 1,684 条公式。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	AST-A ↑	Used	$\eta_{2.5}$ ↑	速度 ↑
Hard AST-BPE	0.4121	90.23	97.45	**8.11**	**74.09**	73.44	61.32	16.17
AST-v4	0.3992	98.81	97.45	8.23	72.95	74.61	61.20	**42.12**
Boundary AST	**0.3771**	**99.80**	96.60	17.05	40.96	68.36	68.62	37.07
Math-atom BPE	0.3820	**99.80**	96.60	17.66	38.96	68.26	69.28	11.85
Byte BPE	0.3985	72.12	96.60	20.10	32.93	77.44	**72.66**	9.44
SP Unigram	0.4956	4.04	97.89	16.56	37.51	68.07	54.22	30.64
Qwen2.5	0.5015	2.14	96.60	19.74	32.18	0.95	32.98	3.54
Llama 3	0.5003	2.14	**99.78**	19.90	30.14	1.17	33.51	10.25
o200k	0.4954	3.37	**99.78**	20.30	29.58	0.73	32.67	16.59

表 17 ood_1：训练 31,684、验证 5,214、测试 18,622 条公式。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	AST-A ↑	Used	$\eta_{2.5}$ ↑	速度 ↑
Hard AST-BPE	0.4420	90.15	95.91	**6.29**	**78.62**	77.25	59.95	14.61
AST-v4	0.4239	98.67	95.91	6.81	77.39	79.20	59.80	**27.84**
Boundary AST	**0.4016**	**99.50**	95.60	17.66	40.73	74.51	68.51	25.80
Math-atom BPE	0.4047	**99.50**	95.60	18.36	39.48	74.51	68.93	8.54
Byte BPE	0.4305	26.77	95.60	23.81	27.33	79.98	**73.77**	7.09
SP Unigram	0.4919	3.40	96.37	20.11	29.37	73.93	61.38	20.52
Qwen2.5	0.5330	2.18	95.60	19.92	34.47	1.52	33.36	3.03
Llama 3	0.5281	2.18	**99.31**	20.11	30.46	2.27	33.92	8.41
o200k	0.5251	2.79	**99.31**	20.37	29.74	1.43	33.27	13.44

表 18 ood_2：训练 42,081、验证 6,357、测试 7,334 条公式。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	AST-A ↑	Used	$\eta_{2.5}$ ↑	速度 ↑
Hard AST-BPE	0.4305	91.04	98.80	**7.85**	**75.20**	74.32	62.57	14.87
AST-v4	0.4050	98.98	98.95	8.26	73.38	76.86	62.27	**33.33**
Boundary AST	**0.3831**	**99.81**	98.26	16.90	39.30	69.24	69.66	29.41
Math-atom BPE	0.3881	**99.81**	98.26	17.30	38.02	69.34	69.89	10.46
Byte BPE	0.4138	53.05	98.26	23.57	24.18	79.00	**74.99**	8.70
SP Unigram	0.4990	2.14	99.06	18.79	27.20	71.09	58.57	24.58
Qwen2.5	0.5148	2.21	98.26	18.86	31.52	1.11	32.95	3.29
Llama 3	0.5142	2.21	**99.52**	18.91	30.78	1.35	33.43	9.08
o200k	0.5111	1.81	**99.52**	19.43	29.32	0.84	32.46	14.56

表 19 ood_3：训练 31,313、验证 4,022、测试 20,259 条公式。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	AST-A ↑	Used	$\eta_{2.5}$ ↑	速度 ↑
Hard AST-BPE	0.4136	93.61	97.91	**7.83**	**75.03**	76.07	62.03	14.53
AST-v4	0.3977	99.06	97.93	8.37	73.30	78.42	61.94	**30.84**
Boundary AST	**0.3759**	**99.78**	97.37	17.23	40.19	70.41	69.77	28.18
Math-atom BPE	0.3796	**99.78**	97.37	17.72	38.93	70.61	70.11	9.16
Byte BPE	0.4040	58.77	97.37	23.03	26.87	79.49	**74.41**	7.40
SP Unigram	0.4761	3.73	98.33	19.56	29.74	72.66	59.35	22.63
Qwen2.5	0.5236	1.91	97.37	19.86	30.67	1.52	32.92	3.18
Llama 3	0.5209	1.91	**99.27**	19.96	29.03	2.07	33.41	8.89
o200k	0.5144	2.94	**99.27**	20.32	27.92	1.31	32.71	14.04

表 20 extreme_analysis_equations_to_algebra：训练 16,893、验证 3,298、测试 8,576 条公式。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	AST-A ↑	Used	$\eta_{2.5}$ ↑	速度 ↑
Hard AST-BPE	0.4503	85.90	93.90	**7.20**	**79.49**	74.12	60.90	15.15
AST-v4	0.4351	98.62	93.90	7.51	78.82	75.59	59.90	**30.18**
Boundary AST	**0.4015**	**98.93**	93.19	16.12	44.88	74.90	69.74	27.82
Math-atom BPE	0.4061	**98.93**	93.19	16.42	44.12	74.80	70.07	9.77
Byte BPE	0.4396	54.39	93.19	19.66	36.45	76.86	**72.82**	8.02
SP Unigram	0.5124	2.45	94.21	18.10	33.75	70.90	61.64	21.87
Qwen2.5	0.5294	1.98	93.19	18.59	38.34	1.28	33.51	3.07
Llama 3	0.5228	1.98	**98.76**	18.86	32.27	1.88	34.15	8.62
o200k	0.5221	2.15	**98.76**	19.11	31.27	1.19	33.38	14.24

表 21 extreme_algebra_to_analysis_equations：训练 7,707、验证 1,002、测试 20,420 条公式。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	AST-A ↑	Used	$\eta_{2.5}$ ↑	速度 ↑
Hard AST-BPE	0.4246	88.38	98.30	**7.39**	**77.47**	76.76	60.78	15.05
AST-v4	0.4089	97.93	98.30	7.70	76.79	76.56	59.98	**31.26**
Boundary AST	**0.3824**	**98.22**	97.40	17.06	40.92	74.32	69.01	28.14
Math-atom BPE	0.3873	**98.22**	97.40	17.46	39.46	74.12	69.60	9.35
Byte BPE	0.4175	37.30	97.50	23.39	26.36	77.25	**72.56**	7.39
SP Unigram	0.4914	4.31	98.56	19.50	27.75	71.78	60.88	22.55
Qwen2.5	0.5236	1.91	97.37	19.84	30.70	1.52	32.91	3.19
Llama 3	0.5210	1.91	**99.27**	19.95	29.07	2.07	33.41	8.91
o200k	0.5145	2.94	**99.27**	20.30	27.95	1.31	32.70	14.36

B 实现、复现与审查记录

代码、数据及全部输出位于GitHub 仓库。按下列顺序执行实验、复算和报告生成：

```
.venv/bin/python scripts/run_intrinsic_2026.py
.venv/bin/python scripts/audit_intrinsic_2026.py
.venv/bin/python scripts/build_intrinsic_2026_report.py
```

实验目录为 `experiments/intrinsic_20261015`；协议保存所有训练 / 验证 / 测试 ID、固定参数、代码哈希、数据哈希与环境信息；每组保存训练所得模型、七轮计时、逐式 token ID 及统计量。

审查分五轮执行。第一轮检查 ID、来源、模板、渲染隔离及领域 / 复杂度条件；第二轮检查 1,024 实际 ID 预算、软约束与数学原子共享词表、硬 AST 原生实现与独立参考实现的一致性；第三轮检查所有测试公式的精确负载、完整解码、ID 范围和七轮确定性；第四轮独立重聚合逐式计数与来源组等权 T/B；第五轮从存档 token 与检查点重建边界，复算所有模型的命令、数字与复合节点对齐，抽样以直接区间判据复核 Cross，并调用公开 Rényi 熵函数核对 99 组分布统计。所有检查均通过。

独立审查覆盖 882,738 条模型—公式记录。依赖版本为 tokenizers 0.23.3，sentencepiece 0.2.2，tiktoken 0.14.0，numpy 2.4.6，matplotlib 3.11.2。

B.1 来源组级抽样区间

表 22 全领域测试 T/B 及来源组级 bootstrap 的 95% 区间。每个单元第一行为点估计，第二行为区间；三列分别为三个来源划分。

模型	ID-17	ID-29	ID-43
Hard AST-BPE	0.4253 [0.3988, 0.4520]	0.4220 [0.3965, 0.4490]	0.4069 [0.3856, 0.4272]
AST-v4	0.4094 [0.3843, 0.4360]	0.4027 [0.3788, 0.4290]	0.3897 [0.3703, 0.4086]
Boundary AST	0.3829 [0.3602, 0.4063]	0.3861 [0.3648, 0.4083]	0.3709 [0.3530, 0.3887]
Math-atom BPE	0.3860 [0.3635, 0.4095]	0.3894 [0.3682, 0.4116]	0.3737 [0.3558, 0.3918]
Byte BPE	0.4152 [0.3927, 0.4379]	0.4138 [0.3925, 0.4355]	0.4027 [0.3840, 0.4204]
SP Unigram	0.4827 [0.4636, 0.5020]	0.4782 [0.4598, 0.4957]	0.4741 [0.4576, 0.4898]
Qwen2.5	0.5360 [0.5201, 0.5526]	0.5304 [0.5183, 0.5445]	0.5120 [0.4985, 0.5263]
Llama 3	0.5320 [0.5155, 0.5491]	0.5257 [0.5137, 0.5394]	0.5106 [0.4969, 0.5250]
o200k	0.5257 [0.5073, 0.5452]	0.5206 [0.5080, 0.5350]	0.5057 [0.4907, 0.5219]