数学专用分词器：Benchmark 与泛化实验

肖童仁 [1]

Abstract

本文构建包含 56,000 条 LaTeX 公式的数学分词 benchmark，按领域、来源和复杂度分类。我们研究数学原子 BPE 与软 AST-BPE，并与标准 AST-BPE 及五个基准比较。实验包含领域内、跨领域、极限泛化和简单到复杂四类设置，使用六项指标评价压缩、数学单位完整性、语法跨越、词表使用与编码速度。软 AST-BPE 在 11 组划分中均取得最低 T/B，领域内相对 BPE 减少 7.45% 的每字节 token 数，命令完整率为 99.73%。标准 AST-BPE 的 Cross 更低，软 AST-BPE 则获得更好的压缩与编码吞吐。

1. 引言

通用分词器按照文本频率学习子词，数学公式则包含完整控制命令、数字和嵌套参数。本文研究：利用数学词法与语法信号构造专用分词器，能否同时改善公式压缩、数学单位的完整性和编码速度，并迁移到新的数学领域。

我们构建由 56,000 条 LaTeX 公式组成的 benchmark，比较数学 BPE、软 AST-BPE、标准 AST-BPE 与五个基准分词器。实验从领域内、跨领域、极限泛化和简单到复杂四个方面评价分词器，共包含 11 组划分。本文的主要工作包括：

- 整理具有来源、领域和复杂度分类的数学公式 benchmark，并定义六项评价指标。
- 设计基于数学原子的 BPE 和基于软语法约束的 AST-BPE，与标准硬约束 AST-BPE 比较。
- 在统一语料划分下评价八个分词器，分析压缩、命令完整性、数字完整性、语法跨越和编码速度。

2. 相关工作

词表学习与推理。 BPE 通过高频相邻对合并构建词表 (Sennrich et al., 2016)。Unigram 通过概率估计和剪枝学习子词，并以 Viterbi 选择分割 (Kudo, 2018; Kudo & Richardson, 2018)。词表与推理策略可以分别研究：同一词表采用合并顺序或最短路径，会产生不同的分词结果 (Uzan et al., 2024; Schmidt et al., 2024)。本文数学 BPE 和软 AST-BPE 共享词表，以比较推理阶段的结构引导。

结构引导与分词评价。 AST-BPE 限制合并片段与语法树的层次一致 (Müller & Vlachos, 2019)；AST-T5 利用语法树进行分割和预训练 (Gong et al., 2024)。TokEval 和跨规模分词研究结合压缩、速度与结构性质评价分词器 (Meister, 2026; Lotz et al., 2025)。数字分组也会影响算术计算 (Singh & Strouse, 2024)。本文集中评价数学公式的六项内在指标，并比较数学原子、硬语法约束和软语法约束。

3. Benchmark

3.1. 数据来源与分类

benchmark 包含 56,000 条 LaTeX 公式，覆盖 13 个公式领域。来源包括 283 篇 2020 年前 arXiv 论文、11 篇公开仓库论文和 72 个公式资源模块。

表 1. Benchmark 的公式来源与数量。

来源	公式数
2020 年前 arXiv 论文	51,229
OpenAI 数学仓库	2,810
FunGrim	1,889
SymPy	72
合计	56,000

语料构建分为四步：

1. 获取固定版本的论文源文件或公式资源，提取数学环境。
2. 展开局部宏，检查公式语法与宏展开后的渲染一致性。
3. 去重并保存来源链接、版本、许可和原始位置。
4. 按数学领域、公式类型、来源标签和复杂度分类。

[1] 数学分词器研究项目. Correspondence to: 肖童仁 <github.com/xtr1976536/math-tokenizer-lab>.

Preprint. October 15, 2026.

表 2. 按公式内容划分的领域分布。

领域	数量	领域	数量
分析	20,233	概率	3,171
几何拓扑	9,135	统计	1,056
组合	5,563	逻辑	662
代数	4,431	PDE	356
数论	4,273	ODE	46
数学物理	3,850	线性代数	13
优化	3,211		

来源标签为历史人工、可能混合和未知，分别对应 51,229、2,810 和 1,961 条公式。公式类型包括恒等式与界、求和 / 乘积、积分、多行公式、矩阵和微分关系。论文领域另行记录，用于跨领域划分。

3.2. 公式复杂度

复杂度使用五个量：词素数 L、命令种类 C、括号嵌套深度 D、符号种类 S 和运算符数 O。令 $r(t) = \min(t, 2)$，定义

$$\begin{aligned} K(x) = {} & 0.40r(L/60) + 0.20r(C/6) \\ & + 0.15r(D/3) + 0.15r(S/18) \\ & + 0.10r(O/12). \end{aligned} \tag{1}$$

$K(x) < 0.65$ 为简单公式，否则为复杂公式；两类分别有 37,400 和 18,600 条。例如，语料中的公式 $s^{\frac{1}{3}}$：

- 源码为 `s^{\frac{1}{3}}`，词素数 $L = 11$。
- 只有`\frac` 一种命令，$C = 1$；括号嵌套深度 $D = 2$。
- 非括号符号为 s、`^`、`\frac` 、1、3，故 $S = 5$；运算符为 `^` 和`\frac` ，$O = 2$。

代入式(1)：

$$\begin{aligned} K &= 0.40\frac{11}{60} + 0.20\frac{1}{6} + 0.15\frac{2}{3} \\ &\quad + 0.15\frac{5}{18} + 0.10\frac{2}{12} \\ &= 0.265 < 0.65, \end{aligned}$$

因此该公式属于简单类。

3.3. 评价指标

表 3. 测试公式的实际分词。竖线表示 token 边界。

模型	token 序列
A：$x > \frac{2}{n}$	
AST-BPE	`x |> |\frac |{2} |n`
软 AST-BPE	`x |> |\frac{ |2} |n`
Qwen2.5	`x |>\ |frac |{ |2 |} |n`
B：$y_{m,n}(1) \geq C_{12}$	
AST-BPE	`y_ |{m |, |n} |(1 |) |\geq |C_ |{ |12 |}`
软 AST-BPE	`y |_{m |, |n} |(1 |) |\geq |C |_{1 |2}`
Qwen2.5	`y |_{ |m |,n |}( |1 |)\ |ge |q | C |_{ |1 |2 |}`

我们采用 T/B、Cmd、Num、Cross、Used 和编码速度六项指标，以下按表3的实际分词计算。

T/B ↓：压缩。 单式 T/B 等于 token 数除以原串字节数。表3的公式 A 有 11 字节，软 AST-BPE 与 AST-BPE 均分成 5 个 token：

$$\mathrm{T/B}_A = 5/11 \approx 0.4545.$$

Qwen2.5 使用 7 个 token，对应 $7/11 \approx 0.6364$。实验表先计算每个来源组的总 token 数 / 总字节数，再对来源组取平均：

$$\mathrm{T/B} = \frac{1}{G}\sum_{g=1}^{G}\frac{T_g}{B_g}.$$

Cmd ↑：命令完整率。 公式 A 只有一个命令`\frac` 。AST-BPE 和软 AST-BPE 均未在命令内部切开，Cmd 为 $1/1 = 100\%$；Qwen2.5 将反斜杠与 `frac` 分开，Cmd 为 $0/1 = 0\%$。汇总时用完整命令数除以命令总数。

Num ↑：数字完整率。 公式 B 含数字 1 和 12。AST-BPE 保留两个数字，Num 为 $2/2 = 100\%$；软 AST-BPE 在 12 内部切开，Num 为 $1/2 = 50\%$。汇总时用内部未切开的数字词素数除以数字词素总数。

Cross ↓：语法部分跨越率。 按 KaTeX 语法跨度判断 token 是否部分越过节点。公式 A 的软 AST-BPE 将`\frac` 与左花括号合并，5 个 token 中有 1 个跨越分子组起点：

$$\mathrm{Cross}_A = 1/5 \times 100\% = 20\%.$$

AST-BPE 保留分子组，Cross 为 $0/5 = 0\%$。实验表用跨越 token 数除以全部 token 数，每个 token 最多计一次。

Used：词表使用率。 统计输入中出现过的不同 ID，除以词表大小：

$$\mathrm{Used} = \frac{\text{已使用的不同 ID 数}}{\text{词表 ID 总数}} \times 100\%.$$

公式 B 在软 AST-BPE 下使用 10 个不同 ID，因此单式 Used 为 $10/1024 \times 100\% = 0.9766\%$。该组完整测试集使用 696 个 ID，Used 为 $696/1024 \times 100\% = 67.97\%$。

速度↑：完整编码吞吐。 用原始输入 MiB 除以完整编码时间：

$$\text{Speed} = \frac{\text{输入字节数}/2^{20}}{\text{编码秒数}}.$$

同组公式 A、B 所在的完整测试集有 659,113 字节；软 AST-BPE 七轮编码的中位耗时为 0.02121125 秒：

$$\text{Speed} = \frac{659113/2^{20}}{0.02121125} \approx 29.63 \text{ MiB/s}.$$

计时包含原子映射、解析和分割，模型加载与指标计算在计时之外。

4. 分词器

比较模型包括三个数学分词器和五个基准。五个在本语料上训练的模型均使用 1,024 个 ID；Qwen2.5、Llama 3 和 o200k 采用官方完整词表。

4.1. AST-BPE

AST-BPE 采用Müller & Vlachos (2019) 的硬约束合并原则。数学前端提取算术、分式、根式、括号和上下标的结构跨度，其他命令采用参数绑定结构。

1. 从字节序列出发，统计与语法层次兼容的相邻 token 对。
2. 选择频率最高的合法对合并，更新计数，直至词表达到 1,024。
3. 推理时按学习到的规则顺序合并，并对每次合并施加同样的硬约束。

若 token 区间 $[a, b)$ 与节点 $[u, v)$ 满足 $a < u < b < v$ 或 $u < a < v < b$，该合并被禁止。例如表3中的`\frac` 和分子组分别保留，避免把命令末尾与分子组开头合在一起。

4.2. 数学 BPE

数学 BPE 在基础字母表中保护完整数学命令，再使用官方 BPE 学习词表和执行分词。

1. 从训练集选取至多 384 个高频控制命令和非 ASCII 字符，加上 256 个基础字节。
2. 将已选完整命令映射为单个基础符号，使用 Hugging Face BPE 训练到 1,024 个 ID。
3. 推理先执行相同原子映射，再调用官方 BPE。原子内部保持完整，原子之间可以合并。

表 4. 模型容量与代码来源。AST-BPE 采用公开算法的数学迁移实现。

模型	ID 空间	来源
AST-BPE	1,024	代码
软 AST-BPE	1,024	代码
数学 BPE	1,024	代码
BPE	1,024	代码
Unigram	1,024	代码
Qwen2.5	151,665	代码
Llama 3	128,256	代码
o200k	200,019	代码

4.3. 软 AST-BPE

软 AST-BPE 与数学 BPE 共享词表，在候选分割上加入语法代价。设 $T(z)$ 为 token 数，$C(z)$ 为跨越前端语法跨度的 token 数，$H(z)$ 为被 token 覆盖的花括号组内容端点数，目标为

$$z^* = \arg\min_z \big[T(z) + 0.25C(z) + 0.30H(z)\big]. \quad (2)$$

1. 用 trie 查找当前位置可用的词表片段。
2. 为每个候选片段计算 token 代价和结构代价。
3. 用动态规划求总代价最小的分割。解析、匹配和路径搜索由原生 C 实现完成。

表3中，软约束允许命令与左花括号合并；数学命令内部仍由原子约束保护。

4.4. 基准分词器

- **BPE**：Hugging Face 字节 BPE；256 个基础字节计入 1,024 个 ID。
- **Unigram**：SentencePiece 通过 EM 与候选剪枝学习词表，推理采用 Viterbi。使用 identity 归一化、byte fallback 和原始空白。
- **Qwen2.5**：千问 2.5 系列官方分词器，151,665 个 ID。
- **Llama 3**：Meta Llama 3 官方分词器，128,256 个 ID。
- **o200k**：官方 tiktoken 编码，200,019 个 ID。

5. 实验

5.1. 实验设置

每次划分以整篇论文或资源模块为来源组，清除训练、验证和测试之间的模板及渲染重复。训练集用于学习词表；验证公式不进入词表。词表大小、原子预算和式(2)的权重在所有实验中保持一致。

- **领域内**：各领域均参与训练和测试，按来源组约 80% / 10% / 10% 划分，重复三次。
- **跨领域**：每次完整留出三个学科，用其他学科训练，共三个留出组合。

表 5. 四类实验的实际公式数量。跨领域行名表示测试领域；极限泛化行名表示迁移方向。

实验	划分 / 测试领域	训练	验证	测试
领域内	划分 1	44,070	4,656	7,022
领域内	划分 2	43,262	8,317	4,184
领域内	划分 3	44,515	5,516	5,725
跨领域	几何 / 组合 / 数论	31,684	5,214	18,622
跨领域	概率 / 统计 / 优化	42,081	6,357	7,334
跨领域	分析 / PDE / ODE	31,313	4,022	20,259
极限泛化	分析方程 → 代数	16,893	3,298	8,576
极限泛化	代数 → 分析方程	7,707	1,002	20,420
简单到复杂	划分 1	29,863	3,032	2,769
简单到复杂	划分 2	29,119	5,347	1,487
简单到复杂	划分 3	29,347	3,768	1,684

- **极限泛化**：分析 / PDE / ODE 与代数 / 数论 / 线性代数两个学科族双向迁移。
- **简单到复杂**：只用简单公式训练，在独立来源的复杂公式上测试，重复三次。

5.2. 实验结果

表6至表9依次给出四个实验的完整结果。领域内、跨领域和简单到复杂分别对三个设置取平均，极限泛化对两个方向取平均；每次划分的结果见附录。Cmd、Num、Cross 和 Used 以百分数表示，速度单位为 MiB/s。

表 6. 领域内实验：三个来源划分的均值。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	Used	速度 ↑
AST-BPE	0.4181	92.28	96.87	**7.71**	74.74	14.81
软 AST-BPE	**0.3799**	**99.73**	96.37	17.50	67.97	**29.36**
数学 BPE	0.3830	**99.73**	96.37	18.18	68.03	10.00
BPE	0.4105	36.27	96.37	25.17	78.26	8.49
Unigram	0.4783	4.18	97.42	19.80	71.65	23.76
Qwen2.5	0.5261	2.02	96.37	19.98	1.02	3.15
Llama 3	0.5228	2.02	**99.23**	20.14	1.30	9.00
o200k	0.5174	2.62	**99.23**	20.58	0.81	14.28

表 7. 跨领域实验：三个留出组合的均值。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	Used	速度 ↑
AST-BPE	0.4287	91.60	97.54	**7.32**	75.88	14.67
软 AST-BPE	**0.3869**	**99.70**	97.08	17.26	71.39	**27.80**
数学 BPE	0.3908	**99.70**	97.08	17.79	71.48	9.39
BPE	0.4161	46.20	97.08	23.47	79.49	7.73
Unigram	0.4890	3.09	97.92	19.49	72.56	22.57
Qwen2.5	0.5238	2.10	97.08	19.54	1.38	3.17
Llama 3	0.5211	2.10	**99.36**	19.66	1.90	8.80
o200k	0.5169	2.52	**99.36**	20.04	1.19	14.01

表 8. 极限泛化实验：两个迁移方向的均值。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	Used	速度 ↑
AST-BPE	0.4374	87.14	96.10	**7.30**	75.44	15.10
软 AST-BPE	**0.3919**	**98.58**	95.29	16.59	74.61	**27.98**
数学 BPE	0.3967	**98.58**	95.29	16.94	74.46	9.56
BPE	0.4286	45.84	95.34	21.52	77.05	7.71
Unigram	0.5019	3.38	96.39	18.80	71.34	22.21
Qwen2.5	0.5265	1.95	95.28	19.22	1.40	3.13
Llama 3	0.5219	1.95	**99.01**	19.40	1.98	8.76
o200k	0.5183	2.54	**99.01**	19.71	1.25	14.30

表 9. 简单到复杂实验：三个来源划分的均值。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	Used	速度 ↑
AST-BPE	0.4226	86.17	96.91	**7.63**	73.11	16.38
软 AST-BPE	**0.3802**	**99.62**	96.13	17.96	67.25	**36.33**
数学 BPE	0.3852	**99.62**	96.13	19.16	67.06	11.88
BPE	0.4084	64.80	96.13	21.50	76.89	9.56
Unigram	0.5020	2.72	97.42	16.00	67.84	29.80
Qwen2.5	0.5142	2.73	96.13	20.40	0.87	3.47
Llama 3	0.5110	2.73	**99.14**	20.58	1.09	10.12
o200k	0.5058	3.29	**99.14**	21.09	0.68	16.31

5.3. 结果分析

- **压缩**：软 AST-BPE 在 11 组划分中均取得最低 T/B；四类实验相对 BPE 分别减少 7.45%、7.02%、8.54% 和 6.91%。
- **命令与数字**：领域内实验中，软 AST-BPE 和数学 BPE 的 Cmd 均为 99.73%，BPE 为 36.27%；Llama 3 和 o200k 的 Num 均为 99.23%，高于数学专用模型。
- **结构与速度**：AST-BPE 的 Cross 为 7.71%，软 AST-BPE 为 17.50%；硬约束产生更少部分跨越。软 AST-BPE 速度为 29.36 MiB/s，数学 BPE 为 10.00 MiB/s。

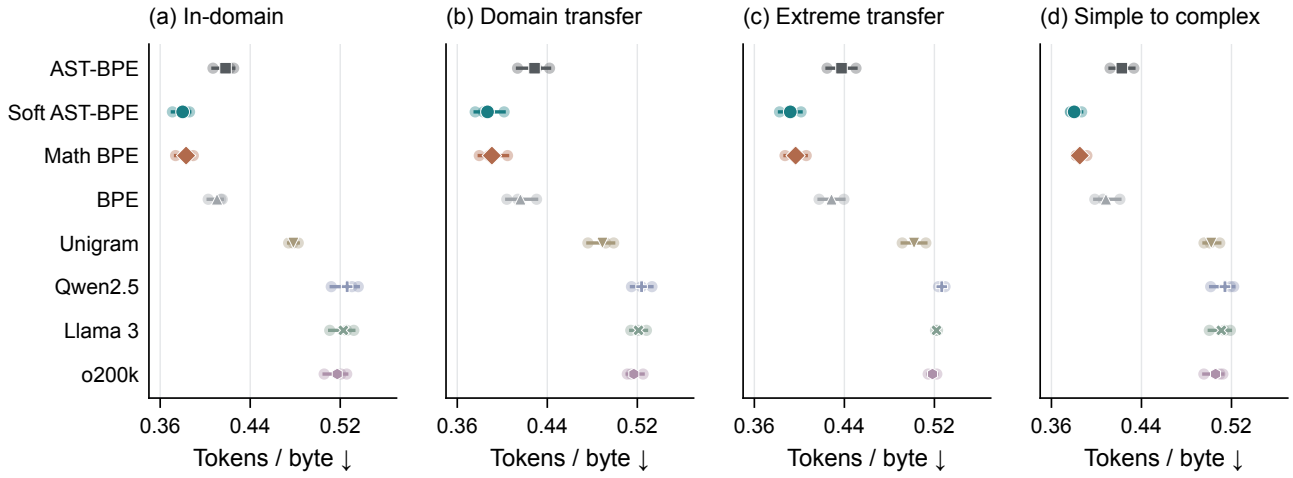


图 1. 四类实验的 T/B。小点为各次来源划分或迁移设置，线段为范围，大标记为等权均值；每列分别包含 3、3、2、3 组设置。

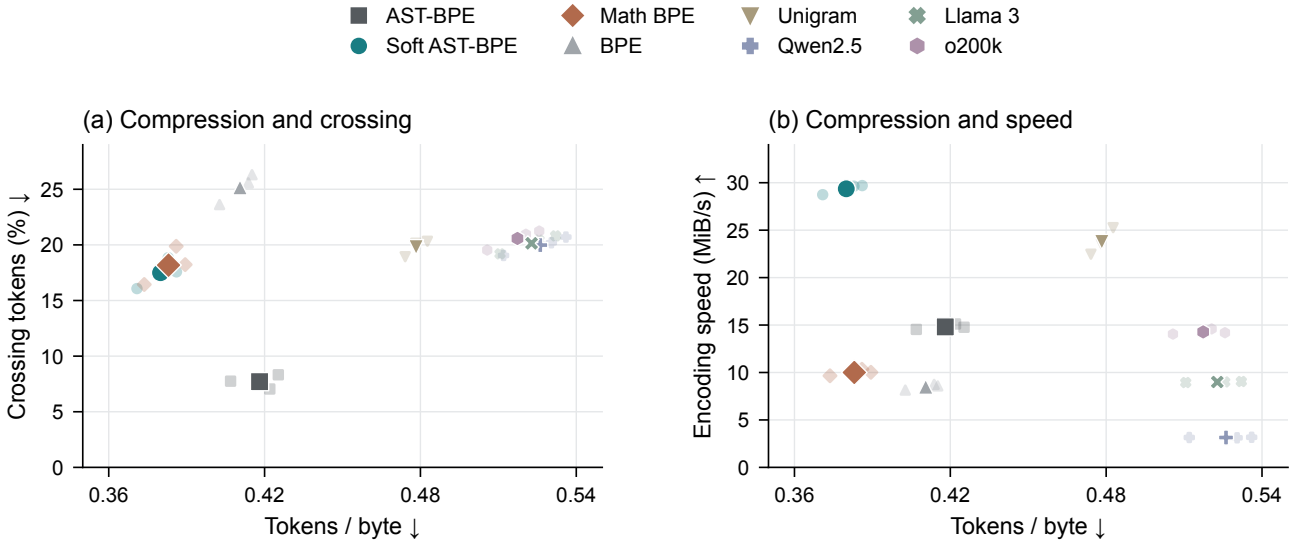


图 2. 领域内三个来源划分的压缩、Cross 与编码速度。小点为单次划分，大标记为均值。左图比较压缩与语法跨越，右图比较完整编码接口吞吐。

6. 结论

本文构建了具有领域、来源和复杂度分类的数学公式 benchmark，并用四类泛化实验比较八个分词器。数学 BPE 通过完整命令原子改善数学单位表示；软 AST-BPE 在共享词表上加入结构代价，在 11 组划分中均获得最低 T/B，领域内命令完整率为 99.73%，编码速度为 29.36 MiB/s。标准 AST-BPE 取得更低 Cross，显示硬约束与软约束各自的结构与压缩优势。

References

Gong, L., Elhoushi, M., and Cheung, A. AST-t5: Structure-aware pretraining for code generation and understanding. In *Proceedings of the 41st International Conference on Machine Learning*, volume 235, pp. 15839–15853. PMLR, 2024. URL https://proceedings.mlr.press/v235/gong24c.html.

Kudo, T. Subword regularization: Improving neural network translation models with multiple subword candidates. In Gurevych, I. and Miyao, Y. (eds.), *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 66–75, Melbourne, Australia, July 2018. Association for Computational Linguistics. doi: 10.18653/v1/P18-1007. URL https://aclanthology.org/P18-1007/.

Kudo, T. and Richardson, J. SentencePiece: A simple and language independent subword tokenizer and detokenizer for neural text processing. In Blanco, E. and Lu, W. (eds.), *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pp. 66–71, Brussels, Belgium, November 2018. Association for Computational Linguistics. doi: 10.18653/v1/D18-2012. URL https://aclanthology.org/D18-2012/.

Lotz, J. F., Lopes, A. V., Peitz, S., Setiawan, H., and Emili, L. Beyond text compression: Evaluating tokenizers across scales. In Che, W., Nabende, J., Shutova, E., and Pilehvar, M. T. (eds.), *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 32155–32173, Vienna, Austria, July 2025. Association for Computational Linguistics. ISBN 979-8-89176-251-0. doi: 10.18653/v1/2025.acl-long.1546. URL https://aclanthology.org/2025.acl-long.1546/.

Meister, C. TokEval: A tokenizer evaluation suite. *arXiv preprint arXiv:2608.18062*, 2026. URL https://arxiv.org/abs/2608.18062.

Müller, S. and Vlachos, A. Byte-pair encoding for text-to-sql generation. *arXiv preprint arXiv:1910.08962*, 2019. URL https://arxiv.org/abs/1910.08962.

Schmidt, C. W., Reddy, V., Zhang, H., Alameddine, A., Uzan, O., Pinter, Y., and Tanner, C. Tokenization is more than compression. In Al-Onaizan, Y., Bansal, M., and Chen, Y.-N. (eds.), *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, pp. 678–702, Miami, Florida, USA, November 2024. Association for Computational Linguistics. doi: 10.18653/v1/2024.emnlp-main.40. URL https://aclanthology.org/2024.emnlp-main.40/.

Sennrich, R., Haddow, B., and Birch, A. Neural machine translation of rare words with subword units. In Erk, K. and Smith, N. A. (eds.), *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 1715–1725, Berlin, Germany, August 2016. Association for Computational Linguistics. doi: 10.18653/v1/P16-1162. URL https://aclanthology.org/P16-1162/.

Singh, A. K. and Strouse, D. Tokenization counts: the impact of tokenization on arithmetic in frontier LLMs. *arXiv preprint arXiv:2402.14903*, 2024. URL https://arxiv.org/abs/2402.14903.

Uzan, O., Schmidt, C. W., Tanner, C., and Pinter, Y. Greed is all you need: An evaluation of tokenizer inference methods. In Ku, L.-W., Martins, A., and Srikumar, V. (eds.), *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, pp. 813–822, Bangkok, Thailand, August 2024. Association for Computational Linguistics. doi: 10.18653/v1/2024.acl-short.73. URL https://aclanthology.org/2024.acl-short.73/.

A. 各次划分的结果

各表沿用正文的六项指标。领域内和简单到复杂实验使用三个来源划分；跨领域实验采用三个留出组合；极限泛化分别报告两个迁移方向。

表 10. 领域内：划分 1。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	Used	速度 ↑
AST-BPE	0.4253	92.92	98.14	**8.32**	75.00	14.77
软 AST-BPE	**0.3829**	**99.92**	97.63	18.85	67.97	**29.63**
数学 BPE	0.3860	**99.92**	97.63	19.87	68.16	10.34
BPE	0.4152	38.04	97.63	26.31	78.71	8.59
Unigram	0.4827	4.16	98.38	20.32	71.00	25.26
Qwen2.5	0.5360	2.54	97.63	20.70	1.04	3.17
Llama 3	0.5320	2.54	**98.67**	20.81	1.31	9.05
o200k	0.5257	2.92	**98.67**	21.24	0.81	14.19

表 11. 领域内：划分 2。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	Used	速度 ↑
AST-BPE	0.4220	91.85	95.77	**7.05**	74.22	15.11
软 AST-BPE	**0.3861**	**99.37**	95.43	17.57	66.80	**29.70**
数学 BPE	0.3894	**99.37**	95.43	18.23	66.99	10.02
BPE	0.4138	38.62	95.43	25.58	76.95	8.75
Unigram	0.4782	3.87	96.53	20.15	71.29	23.56
Qwen2.5	0.5304	2.02	95.43	20.19	0.89	3.12
Llama 3	0.5257	2.02	**99.33**	20.43	1.17	9.00
o200k	0.5206	2.36	**99.33**	20.96	0.74	14.59

表 12. 领域内：划分 3。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	Used	速度 ↑
AST-BPE	0.4069	92.07	96.71	**7.75**	75.00	14.54
软 AST-BPE	**0.3709**	**99.92**	96.06	16.07	69.14	**28.74**
数学 BPE	0.3737	**99.92**	96.06	16.44	68.95	9.65
BPE	0.4027	32.14	96.06	23.62	79.10	8.15
Unigram	0.4741	4.52	97.34	18.93	72.66	22.47
Qwen2.5	0.5120	1.51	96.06	19.05	1.13	3.15
Llama 3	0.5106	1.51	**99.70**	19.19	1.41	8.94
o200k	0.5057	2.56	**99.70**	19.53	0.87	14.05

表 13. 跨领域：几何 / 组合 / 数论。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	Used	速度 ↑
AST-BPE	0.4420	90.15	95.91	**6.29**	77.25	14.61
软 AST-BPE	**0.4016**	**99.50**	95.60	17.66	74.51	**25.80**
数学 BPE	0.4047	**99.50**	95.60	18.36	74.51	8.54
BPE	0.4305	26.77	95.60	23.81	79.98	7.09
Unigram	0.4919	3.40	96.37	20.11	73.93	20.52
Qwen2.5	0.5330	2.18	95.60	19.92	1.52	3.03
Llama 3	0.5281	2.18	**99.31**	20.11	2.27	8.41
o200k	0.5251	2.79	**99.31**	20.37	1.43	13.44

表 14. 跨领域：概率 / 统计 / 优化。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	Used	速度 ↑
AST-BPE	0.4305	91.04	98.80	**7.85**	74.32	14.87
软 AST-BPE	**0.3831**	**99.81**	98.26	16.90	69.24	**29.41**
数学 BPE	0.3881	**99.81**	98.26	17.30	69.34	10.46
BPE	0.4138	53.05	98.26	23.57	79.00	8.70
Unigram	0.4990	2.14	99.06	18.79	71.09	24.58
Qwen2.5	0.5148	2.21	98.26	18.86	1.11	3.29
Llama 3	0.5142	2.21	**99.52**	18.91	1.35	9.08
o200k	0.5111	1.81	**99.52**	19.43	0.84	14.56

表 15. 跨领域：分析 / PDE / ODE。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	Used	速度 ↑
AST-BPE	0.4136	93.61	97.91	**7.83**	76.07	14.53
软 AST-BPE	**0.3759**	**99.78**	97.37	17.23	70.41	**28.18**
数学 BPE	0.3796	**99.78**	97.37	17.72	70.61	9.16
BPE	0.4040	58.77	97.37	23.03	79.49	7.40
Unigram	0.4761	3.73	98.33	19.56	72.66	22.63
Qwen2.5	0.5236	1.91	97.37	19.86	1.52	3.18
Llama 3	0.5209	1.91	**99.27**	19.96	2.07	8.89
o200k	0.5144	2.94	**99.27**	20.32	1.31	14.04

表 16. 极限泛化：分析方程 → 代数。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	Used	速度 ↑
AST-BPE	0.4503	85.90	93.90	**7.20**	74.12	15.15
软 AST-BPE	**0.4015**	**98.93**	93.19	16.12	74.90	**27.82**
数学 BPE	0.4061	**98.93**	93.19	16.42	74.80	9.77
BPE	0.4396	54.39	93.19	19.66	76.86	8.02
Unigram	0.5124	2.45	94.21	18.10	70.90	21.87
Qwen2.5	0.5294	1.98	93.19	18.59	1.28	3.07
Llama 3	0.5228	1.98	**98.76**	18.86	1.88	8.62
o200k	0.5221	2.15	**98.76**	19.11	1.19	14.24

表 17. 极限泛化：代数 → 分析方程。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	Used	速度 ↑
AST-BPE	0.4246	88.38	98.30	**7.39**	76.76	15.05
软 AST-BPE	**0.3824**	**98.22**	97.40	17.06	74.32	**28.14**
数学 BPE	0.3873	**98.22**	97.40	17.46	74.12	9.35
BPE	0.4175	37.30	97.50	23.39	77.25	7.39
Unigram	0.4914	4.31	98.56	19.50	71.78	22.55
Qwen2.5	0.5236	1.91	97.37	19.84	1.52	3.19
Llama 3	0.5210	1.91	**99.27**	19.95	2.07	8.91
o200k	0.5145	2.94	**99.27**	20.30	1.31	14.36

表 18. 简单到复杂：划分 1。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	Used	速度 ↑
AST-BPE	0.4223	83.58	98.04	**7.82**	74.71	16.26
软 AST-BPE	**0.3768**	**99.86**	97.36	18.46	67.77	**34.97**
数学 BPE	0.3822	**99.86**	97.36	20.53	67.68	11.65
BPE	0.4059	67.29	97.36	21.61	78.22	9.44
Unigram	0.5009	1.60	98.26	15.58	68.16	28.89
Qwen2.5	0.5219	3.27	97.36	20.90	0.90	3.43
Llama 3	0.5190	3.27	**98.45**	20.99	1.13	10.06
o200k	0.5123	3.68	**98.45**	21.51	0.70	16.03

表 19. 简单到复杂：划分 2。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	Used	速度 ↑
AST-BPE	0.4333	84.70	95.23	**6.97**	71.19	16.71
软 AST-BPE	**0.3868**	**99.20**	94.42	18.35	65.62	**36.95**
数学 BPE	0.3915	**99.20**	94.42	19.31	65.23	12.12
BPE	0.4208	55.01	94.42	22.79	75.00	9.81
Unigram	0.5096	2.50	96.11	15.85	67.29	29.88
Qwen2.5	0.5192	2.78	94.42	20.57	0.75	3.42
Llama 3	0.5136	2.78	**99.20**	20.86	0.97	10.05
o200k	0.5097	2.83	**99.20**	21.45	0.61	16.30

表 20. 简单到复杂：划分 3。

模型	T/B ↓	Cmd ↑	Num ↑	Cross ↓	Used	速度 ↑
AST-BPE	0.4121	90.23	97.45	**8.11**	73.44	16.17
软 AST-BPE	**0.3771**	**99.80**	96.60	17.05	68.36	**37.07**
数学 BPE	0.3820	**99.80**	96.60	17.66	68.26	11.85
BPE	0.3985	72.12	96.60	20.10	77.44	9.44
Unigram	0.4956	4.04	97.89	16.56	68.07	30.64
Qwen2.5	0.5015	2.14	96.60	19.74	0.95	3.54
Llama 3	0.5003	2.14	**99.78**	19.90	1.17	10.25
o200k	0.4954	3.37	**99.78**	20.30	0.73	16.59