数学分词与 PDE 发现
三模型方法及八案例实验

Tongren Xiao

tongrenxiao7@gmail.com

Department of Mathematics, Sun Yat-sen University

2026 年 10 月 21 日

三个模型比较什么

任务：从观测场发现控制方程

输入 (x, t, u) 的观测值，恢复 PDE 的项结构，并估计系数。

$$\sum_{j=1}^{K} c_j \, \phi_j(u, x, t, \partial u, \ldots) = 0.$$

角色	表示与生成方式
基准 EqGPT	固定 GRE 字典，SAT 约束采样
我们的 AST-BPE	硬结构约束学习词表，连续 LaTeX 生成
我们的 Soft-AST-BPE	数学原子 BPE 词表，软结构代价分词，连续 LaTeX 生成

GRE：词表片段（共 57 IDs）

靠前部分

ID	Token
0	<pad>
1	E
2	+
3	*
4	/
5	S

中间部分

ID	Token
26	uxxxxx
27	ut^3
28	sqrt(u)
29	sin(u)
30	sinh(u)
31	BiLaplace(u)

末尾部分

ID	Token
51	t
52	uyyy
53	(uux)t
54	(uux)xx
55	(u^3)xx
56	(u(u^2)xx)xx

AST-BPE：词表片段（共 896 IDs）

靠前部分

ID	Token
0	PAD
1	EOS
2	BOS
35	<space>
120	u
259	u_

中间部分

ID	Token
443	(u_{y})\cdot (y)
444	(u)+
445	(u_{xx})+
446	(y)\cdot (u_{y})
447	{u_{t}

末尾部分

ID	Token
891	\partial_{xx}{\frac{1}{u}}
892	({u}^{3})\cdot (u_{x})
893	({u}^{3})\cdot (u_{xxx})
894	(u_{tt})+(\Delta^{2}{u}
895	\partial_{x}{(u\cdot u_{x})})+(u_{xxxx})=0

Soft-AST-BPE：词表片段（共 896 IDs）

靠前部分

ID	Token
0	PAD
1	EOS
2	BOS
223	<space>
87	u
259	\cdot

中间部分

ID	Token
443	})+(u_{x})/(x)=0
444	({x}^{2})=0
445	(u_{x})\cdot (u)+(u_{t
446	})/({x}^{2
447	})+(\partial_{x}{(u\cdot u_{x})})=0

末尾部分

ID	Token
891	(u_{xxx})+(u_{x
892	(u)+(u_{t})=0
893	(u)\cdot (u_{x})+(u_{xxx
894	})+({u}^{2})+(u_{xx})=0
895	})+({u}^{2})+(u)=0

真实分词结果 1

$$(\partial_{xx}(u \cdot u_x)) + (u_{xxt}) = 0$$

EqGPT

5:S / 54:(uux)xx / 2:+ / 10:uxxt / 1:E
Wave，cycle 1，attempt 163（0-based）

AST-BPE

586:(\partial_{xx}{(u\cdot u_{x})} / 860:)+(u_{xxt} / 317:)=0 / 1:EOS
Wave，cycle 1，attempt 259（0-based）

Soft-AST-BPE

779:(\partial_{xx}{(u\cdot u_{x})})+(u_{xxt})=0 / 1:EOS
Wave，cycle 1，attempt 43（0-based）

真实分词结果 2

$$(\partial_x(u^{-2} \cdot u_x)) + (u_t) = 0$$

EqGPT

5:S / 25:(u^-2*ux)x / 2:+ / 6:ut / 1:E

Wave，cycle 3，attempt 18（0-based）

AST-BPE

850:(\partial_{x}{({u}^{-2}\cdot u_{x})} / 517:)+(u_{t})=0 / 1:EOS

Wave，cycle 1，attempt 86（0-based）

Soft-AST-BPE

785:(\partial_{x}{({u}^{-2}\cdot u_{x})})+(u_{t})=0 / 1:EOS

Wave，cycle 1，attempt 52（0-based）

基准模型 EqGPT：完整流程

Step 1 **数据准备** 同一批过滤后手册方程；每案例拟合同一个观测 surrogate。

↓

Step 2 **GRE 编码** 固定 57-ID 项字典，BOS=5，EOS=1。

↓

Step 3 **GPT 预训练** 6 层 decoder，100 epochs；每方法一套权重供八案例复用。

↓

Step 4 **SAT 约束采样** 每轮 400 次；物理项可用性与项 / 运算符交替约束，80/20 采样。

↓

Step 5 **评分与继续训练** 最小二乘 reward，维护至多 Top-10，继续训练 5 epochs；共 5 轮。

↓

Step 6 **PINN 细化** 最终 Top-3 逐个处理，每候选 500 iterations，记录结构与系数。

蓝色：沿用共同步骤 / 设置　橙色：相对 EqGPT 改变的步骤

EqGPT 的 SAT：约束在采样之前生效

Step 1：根据变量与数值可用性屏蔽词

将下一个 token 概率乘物理项可用性 mask。该 mask 可由数值 reward 更新。

Step 2：约束项与运算符交替

项位置只允许数学项；运算符位置只允许 `E`，`+`，`*`，`/`。然后重新归一化概率。

Step 3：80% 模型概率 + 20% 均匀探索

$$q(v) = 0.8\, p_{\text{masked}}(v) + 0.2\, \text{Unif}(V_{\text{valid}}).$$

我们的模型一：AST-BPE + Transformer

Step 1 **数据准备** 同一批过滤后手册方程；每案例拟合同一个观测 surrogate。

↓

Step 2 **硬 AST-BPE 编码** 连续 LaTeX，冻结 896-ID 词表；BOS=2，EOS=1。

↓

Step 3 **GPT 预训练** 6 层 decoder，100 epochs；每方法一套权重供八案例复用。

↓

Step 4 **无 SAT 的 LaTeX 采样** 全词表 softmax，temperature=1，batch=16，最多 50 新 tokens。

↓

Step 5 **共同 reward 与继续训练** 生成后 LaTeX→GRE；去重复加法项，物理可用性检查，沿用同一评分。

↓

Step 6 **PINN 细化** 最终 Top-3 逐个处理，每候选 500 iterations，记录结构与系数。

蓝色：沿用共同步骤 / 设置　橙色：相对 EqGPT 改变的步骤

我们的模型二：Soft-AST-BPE + Transformer

Step 1 **数据准备** 同一批过滤后手册方程；每案例拟合同一个观测 surrogate。

↓

Step 2 **Soft-AST-BPE 编码** 数学原子 BPE 词表 + 软结构 DP；冻结 896 IDs。

↓

Step 3 **GPT 预训练** 6 层 decoder，100 epochs；每方法一套权重供八案例复用。

↓

Step 4 **无 SAT 的 LaTeX 采样** 全词表 softmax，temperature=1，batch=16，最多 50 新 tokens。

↓

Step 5 **共同 reward 与继续训练** 生成后 LaTeX→GRE；去重复加法项，物理可用性检查，沿用同一评分。

↓

Step 6 **PINN 细化** 最终 Top-3 逐个处理，每候选 500 iterations，记录结构与系数。

蓝色：沿用共同步骤 / 设置　橙色：相对 EqGPT 改变的步骤

共同搜索环：采样、评分、Top-10 与继续训练



reward 的实际定义

$$\hat{c} = \arg\min_{c} \|A_{:,1:}c + A_{:,0}\|_2^2, \qquad R = (1 - 0.2\log_{10} K)R^2.$$

首项系数固定为 1；K 为候选矩阵列数。R^2 衡量 surrogate 上的拟合程度。

固定预算

每模型每案例 5×400=2,000 次尝试。无效候选照常计入；不足 10 条就用现有候选，不补采样。

Benchmark：分词器与模型分别用什么训练

作者手册 PDE_dataset_0725.xlsx：221 条方程

↓

排除 8 个目标名称及同结构别名，共移除 9 行，保留 212 条

↓

原作者交换律增强：每条 32 次，共 6,784 条；唯一 LaTeX 为 3,184 条

训练对象	实际输入
AST / Soft-AST 分词器	上述 6,784 条 GRE 转换得到的连续 LaTeX
AST / Soft-AST Transformer	同一批 LaTeX，用对应冻结分词器编码
EqGPT Transformer	同一批 6,784 条原始 GRE 序列
数值 surrogate / PINN	各测试案例观测场，不是手册字符串

Benchmark：六层 Transformer 与参数量

项目	EqGPT reference	AST-BPE / Soft-AST-BPE
结构	decoder-only，6 层	相同
隐藏宽度 / FFN	768 / 2,048	相同
注意力头 / $d_k = d_v$	8 / 64	相同；QKV 拼接宽度 512
位置 embedding 容量	50	50
词表 / 输入 embedding	57 / 57×768	896 / 896×768
总可训练参数	37,902,393	39,191,936
精度 / dropout	FP32 / 无 dropout	相同

比较边界

相同 backbone 不等于相同总参数。较大词表多出 1,289,543 个参数，约 $+3.40\%$；三模型均从头训练。

Benchmark：预训练与搜索超参数

阶段	参数
共享预训练	100 epochs；6,784 样本；batch=128；53 steps/epoch
优化器与损失	Adam；lr=10^{-4} 恒定；CE(ignore PAD=0)；grad clip=1
训练更新	每模型 5,300 次；全部参数可训练；shuffle=False
搜索预算	8 案例 $\times$3 模型 $\times$5 轮 $\times$400=48,000 次尝试
搜索继续训练	每轮至多 10 条候选，5 epochs；Adam lr=10^{-5}
LaTeX 采样	batch=16，temperature=1，全词表；最多 50 新 tokens / 2,048 bytes
GRE 采样	SAT；80% 模型 +20% 均匀；总序列长度受 50 位置约束
随机性	单种子 seed=525；确定性设置；共享预训练只做一次

实际序列长度

含控制符的训练最大长度：GRE=19，AST-BPE=17，Soft-AST-BPE=12。无训练截断。

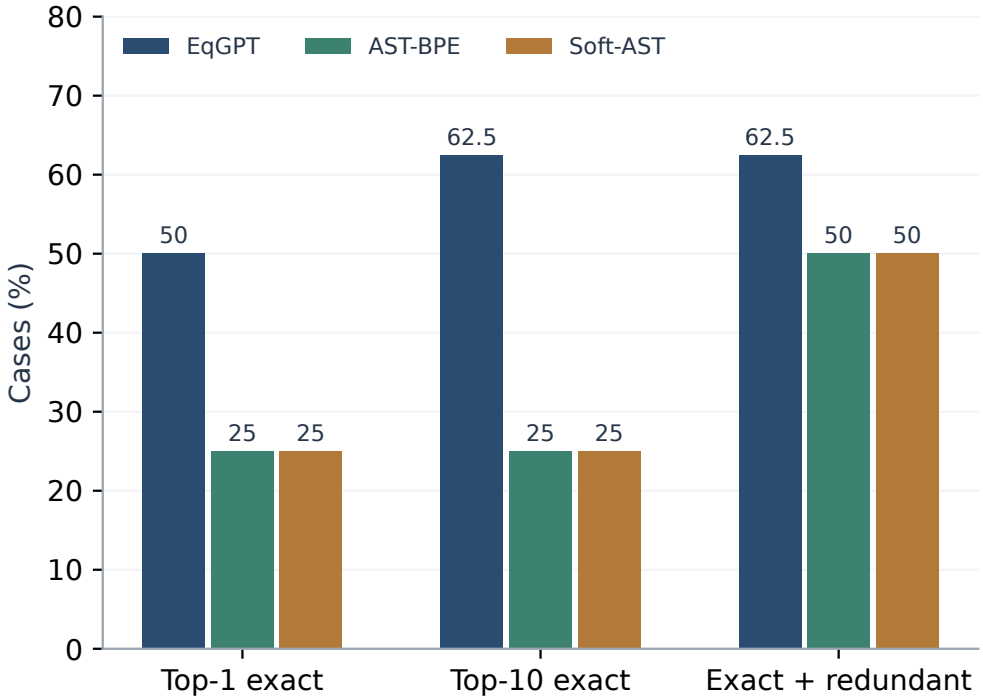
Benchmark：八个测试案例

序	测试案例	正确 PDE
1	Wave	$u_{tt} - u_{xx} = 0$
2	Convection–diffusion	$u_t + u_x - 0.25u_{xx} = 0$
3	Klein–Gordon	$u_{tt} - 0.5u_{xx} + 5u = 0$
4	Burgers	$u_t + uu_x - 0.1u_{xx} = 0$
5	Eq. 6.2.12	$u_t + 0.1u_{xt} + 0.1u_x = 0$
6	PDE divide	$u_t + u_x/x + 0.25u_{xx} = 0$
7	KdV	$u_t + uu_x + 0.0025u_{xxx} = 0$
8	Chafee–Infante	$u_t - u_{xx} + u - u^3 = 0$

结果总览：基准的 exact 命中率较高

模型	Top1	Top10	含冗余	PINN
EqGPT	4/8	5/8	5/8	5
AST-BPE	2/8	2/8	4/8	7
Soft-AST	2/8	2/8	4/8	7

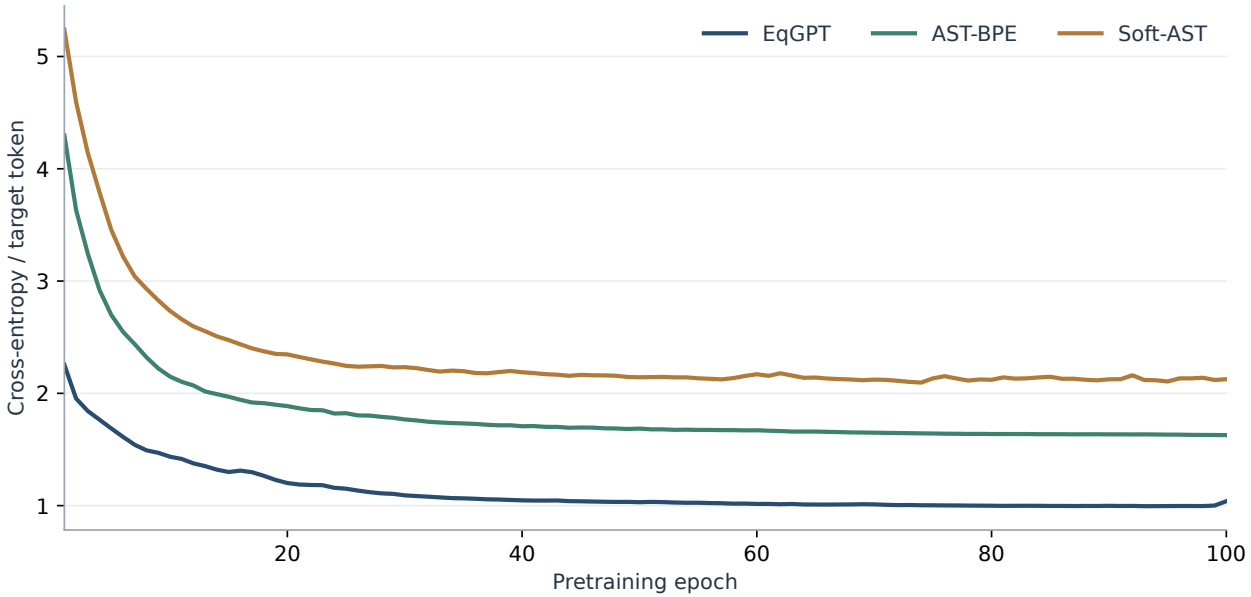
分母均为 8。含冗余 =exact+redundant。
PINN 列为 completed 组数。



八案例结构命中矩阵

案例	EqGPT	AST-BPE	Soft-AST-BPE
Wave	Exact	冗余	冗余
Convection–diffusion	Exact	冗余	Exact
Klein–Gordon	错误	错误	错误
Burgers	Exact	Exact	冗余
Eq. 6.2.12	冗余	错误	错误
PDE divide	错误	错误	错误
KdV	Exact	Exact	Exact
Chafee–Infante	错误	错误	错误

100 epochs：预训练 loss 的实际变化

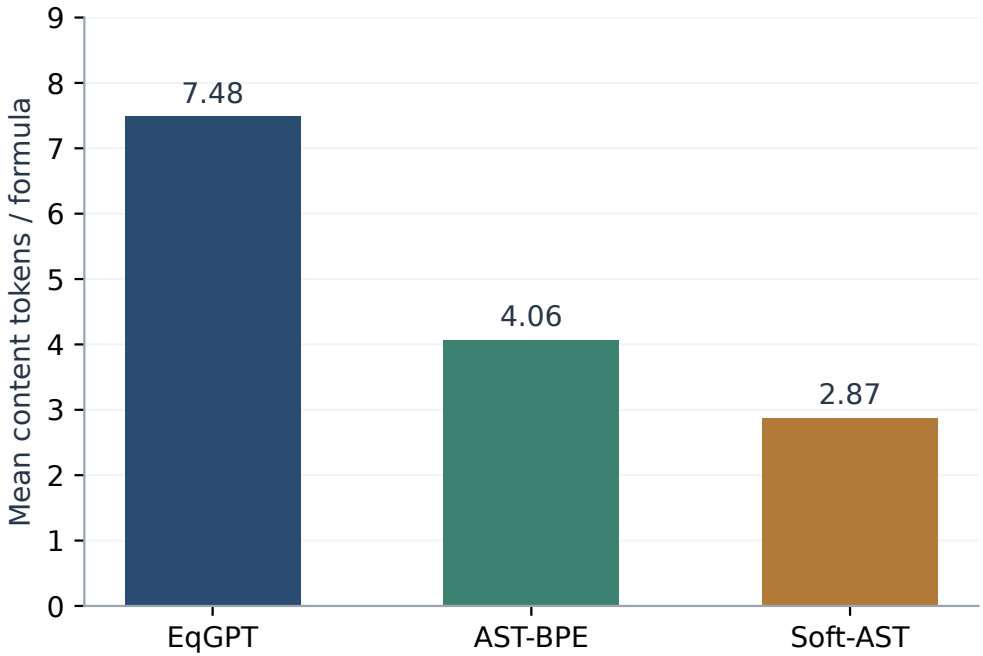


模型	初始	最终
EqGPT	2.255	1.039
AST-BPE	4.298	1.628
Soft-AST	5.239	2.125

序列压缩没有直接带来更高命中率

模型	平均内容 tokens	每轮目标数	最长
EqGPT	7.48	57,536	19
AST-BPE	4.06	34,332	17
Soft-AST	2.87	26,268	12

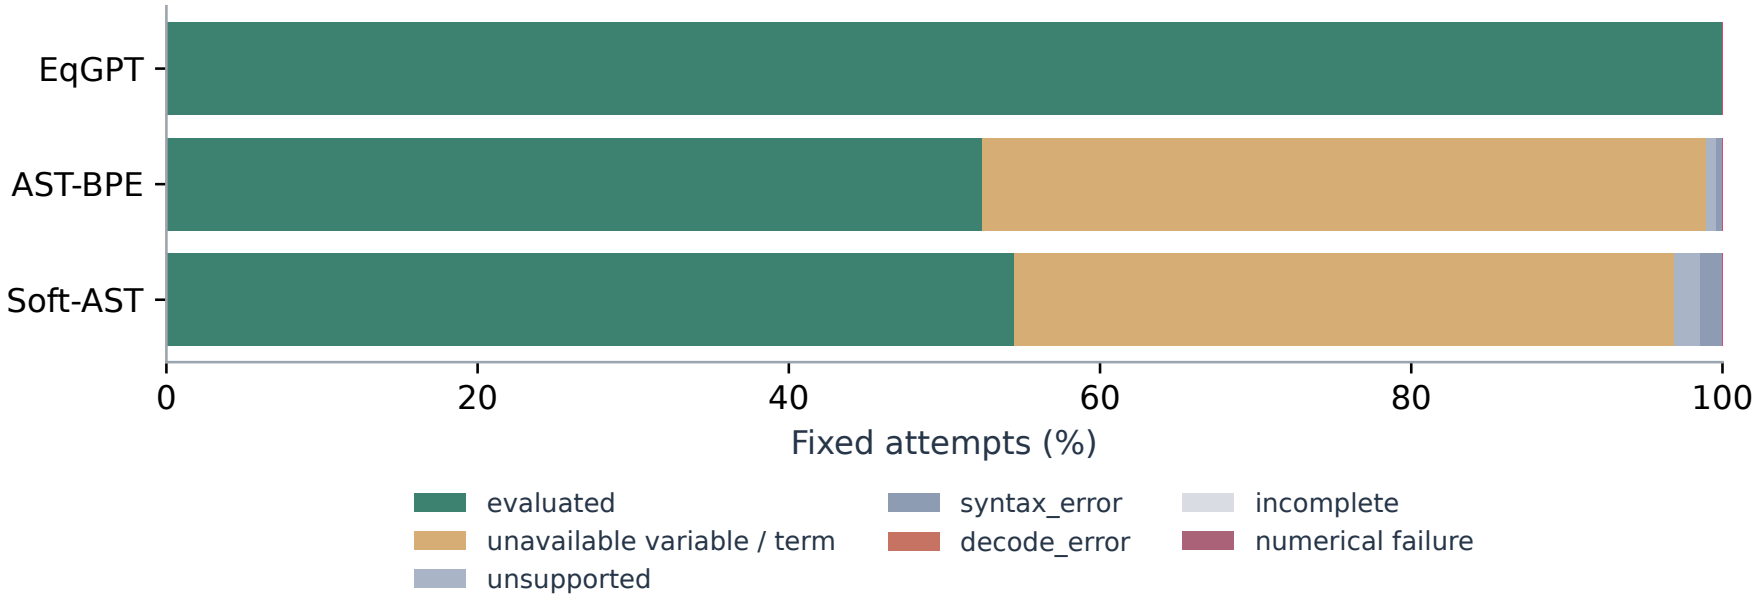
平均内容 tokens 不含两端控制符。最长长度含控制符。



实际差异

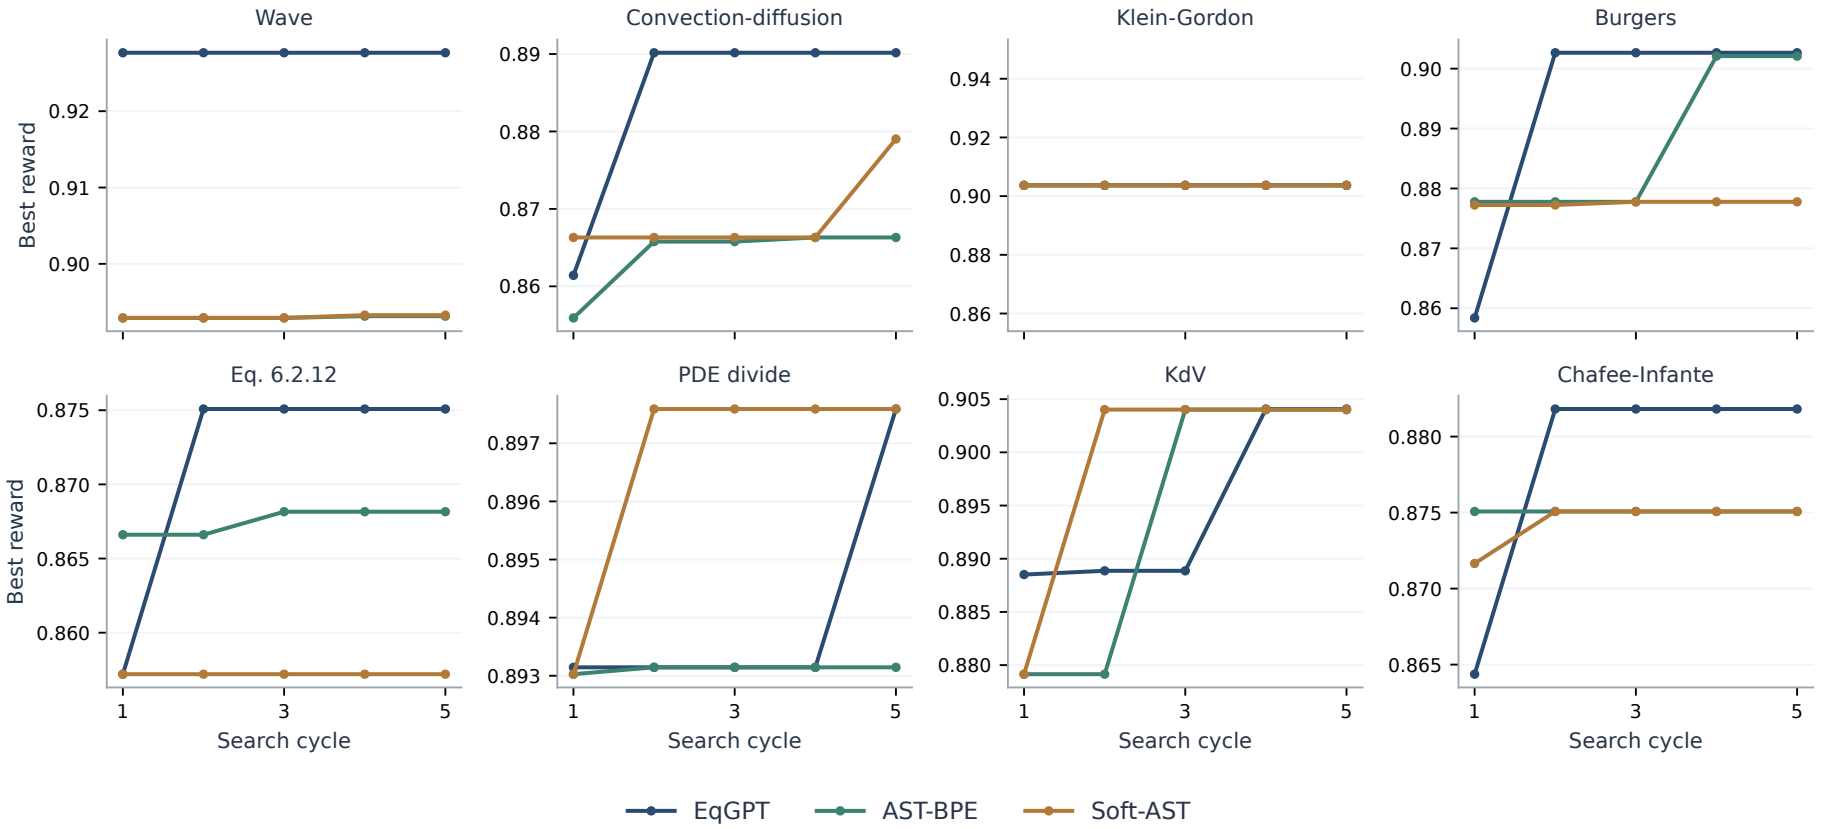
AST-BPE 与 Soft-AST 的平均内容 token 数比 GRE 低约 45.7% 和 61.6%。相同样本 / updates 并不代表相同预测 token 总量；下游 exact 仍为 25%。

采样瓶颈：生成后物理过滤占用了大量预算



模型	可评分 / 16,000	变量或项不可用	其他无效
EqGPT	15,998 (99.99%)	0	2
AST-BPE	8,389 (52.43%)	7,437	174
Soft-AST-BPE	8,723 (54.52%)	6,780	497

五轮搜索：reward 提升与停滞



reward 与 exact 需要分开读

八图都来自固定五轮搜索。高 reward 只说明对当前 surrogate 的拟合好；KG 等错误结构也可取得较高 reward。

案例 1：Wave

正确 PDE

$$u_{tt} - u_{xx} = 0$$

模型	实际 Top-1 项结构（系数待估）	结构	PINN
EqGPT	$c_1 u_{xx} + c_2 u_{tt} = 0$	Exact	完成
AST-BPE	$c_1 u_{xx} + c_2 x^2 u_{xx} + c_3 u_{tt} = 0$	冗余	完成
Soft-AST-BPE	$c_1 u_{xx} + c_2 u_{xxxx} + c_3 u_{tt} = 0$	冗余	完成

Top-1 的最后系数记录（iteration 499）

$$\begin{aligned}
\text{GRE}: &\quad u_{tt} - 1.001\, u_{xx} = 0 \\
\text{AST}: &\quad u_{tt} - 1.002\, u_{xx} + 3.61\times10^{-4}\, x^2\, u_{xx} = 0 \\
\text{Soft}: &\quad u_{tt} - 1.001\, u_{xx} + 8.99\times10^{-6}\, u_{xxxx} = 0
\end{aligned}$$

案例 2：Convection–diffusion

正确 PDE

$$u_t + u_x - 0.25u_{xx} = 0$$

模型	实际 Top-1 项结构（系数待估）	结构	PINN
EqGPT	$c_1 u_t + c_2 u_x + c_3 u_{xx} = 0$	Exact	失败
AST-BPE	$c_1 u_t + c_2 u_x u + c_3 u_x + c_4 u_{xx} = 0$	冗余	完成
Soft-AST-BPE	$c_1 u_x + c_2 u_t + c_3 u_{xx} = 0$	Exact	完成

Top-1 的最后系数记录（iteration 499）

$$\begin{aligned}
\text{GRE}: &\quad u_t + 0.9989\, u_x - 0.2501\, u_{xx} = 0 \\
\text{AST}: &\quad u_t + 0.01984\, u_x\, u + 0.9959\, u_x - 0.2503\, u_{xx} = 0 \\
\text{Soft}: &\quad u_t + 0.9989\, u_x - 0.2501\, u_{xx} = 0
\end{aligned}$$

案例 3：Klein–Gordon

正确 PDE

$$u_{tt} - 0.5u_{xx} + 5u = 0$$

模型	实际 Top-1 项结构（系数待估）	结构	PINN
EqGPT	$c_1 u_{tt} + c_2 \sin u + c_3 u_{xx} = 0$	错误	完成
AST-BPE	$c_1 u_{tt} + c_2 \sin u + c_3 u_{xx} = 0$	错误	完成
Soft-AST-BPE	$c_1 u_{tt} + c_2 \sin u + c_3 u_{xx} = 0$	错误	完成

Top-1 的最后系数记录（iteration 499）

$$\begin{aligned} \text{GRE}: &\quad u_{tt} + 5.136 \sin u - 0.5002\, u_{xx} = 0 \\ \text{AST}: &\quad u_{tt} + 5.136 \sin u - 0.5002\, u_{xx} = 0 \\ \text{Soft}: &\quad u_{tt} + 5.136 \sin u - 0.5002\, u_{xx} = 0 \end{aligned}$$

案例 4：Burgers

正确 PDE

$$u_t + uu_x - 0.1u_{xx} = 0$$

模型	实际 Top-1 项结构（系数待估）	结构	PINN
EqGPT	$c_1\,u\,u_x + c_2\,u_{xx} + c_3\,u_t = 0$	Exact	失败
AST-BPE	$c_1\,u_{xx} + c_2\,u_t + c_3\,u_x\,u = 0$	Exact	完成
Soft-AST-BPE	$c_1\,u\,u_x + c_2\,u_t + c_3\,u_{xx} + c_4\,u_{xxx} = 0$	冗余	完成

Top-1 的最后系数记录（iteration 499）

$$\begin{aligned}
\text{GRE}: &\quad u_t + 0.9984\,u\,u_x - 0.09976\,u_{xx} = 0 \\
\text{AST}: &\quad u_t - 0.1\,u_{xx} + 0.9998\,u_x\,u = 0 \\
\text{Soft}: &\quad u_t + 0.9984\,u\,u_x - 0.09976\,u_{xx} + 1.23\times10^{-6}\,u_{xxx} = 0
\end{aligned}$$

案例 5：Eq. 6.2.12

正确 PDE

$$u_t + 0.1u_{xt} + 0.1u_x = 0$$

模型	实际 Top-1 项结构（系数待估）	结构	PINN
EqGPT	$c_1 u_x + c_2 u_x^2 + c_3 u_{xt} + c_4 u_t = 0$	冗余	完成
AST-BPE	$c_1 u_t + c_2 u_x + c_3 u_{tt} + c_4 u_{xx} = 0$	错误	完成
Soft-AST-BPE	$c_1 u_{xt} + c_2 u_{xx} + c_3 u_{tt} = 0$	错误	完成

Top-1 的最后系数记录（iteration 499）

$$\begin{aligned}
\text{GRE}: &\quad u_t + 0.0969\, u_x + 4.36\times10^{-4}\, u_x^2 + 0.1097\, u_{xt} = 0 \\
\text{AST}: &\quad u_t + 0.1017\, u_x - 0.766\, u_{tt} - 0.01335\, u_{xx} = 0 \\
\text{Soft}: &\quad u_{xt} + 0.1095\, u_{xx} + 5.527\, u_{tt} = 0
\end{aligned}$$

案例 6：PDE divide

正确 PDE

$$u_t + u_x/x + 0.25u_{xx} = 0$$

模型	实际 Top-1 项结构（系数待估）	结构	PINN
EqGPT	$c_1 u_t + c_2 u_x + c_3 x u_{xx} = 0$	错误	完成
AST-BPE	$c_1 u + c_2 u_x u + c_3 u_t = 0$	错误	完成
Soft-AST-BPE	$c_1 u_t + c_2 u_x + c_3 u_{xx} x = 0$	错误	完成

Top-1 的最后系数记录（iteration 499）

$$\begin{aligned} \text{GRE}: &\quad u_t + 0.7842\, u_x - 0.1623\, x\, u_{xx} = 0 \\ \text{AST}: &\quad u_t + 2.946\, u + 0.7149\, u_x\, u = 0 \\ \text{Soft}: &\quad u_t + 0.7842\, u_x - 0.1623\, u_{xx}\, x = 0 \end{aligned}$$

案例 7：KdV

正确 PDE

$$u_t + uu_x + 0.0025u_{xxx} = 0$$

模型	实际 Top-1 项结构（系数待估）	结构	PINN
EqGPT	$c_1\,u\,u_x + c_2\,u_t + c_3\,u_{xxx} = 0$	Exact	**失败**
AST-BPE	$c_1\,u_{xxx} + c_2\,u\,u_x + c_3\,u_t = 0$	Exact	**完成**
Soft-AST-BPE	$c_1\,u_{xxx} + c_2\,u_t + c_3\,u_x\,u = 0$	Exact	**完成**

Top-1 的最后系数记录（iteration 499）

$$\begin{aligned}
\text{GRE}: &\quad u_t + 0.9986\,u\,u_x + 0.002499\,u_{xxx} = 0 \\
\text{AST}: &\quad u_t + 0.002194\,u_{xxx} + 0.6647\,u\,u_x = 0 \\
\text{Soft}: &\quad u_t + 0.002194\,u_{xxx} + 0.6646\,u_x\,u = 0
\end{aligned}$$

案例 8：Chafee–Infante

正确 PDE

$$u_t - u_{xx} + u - u^3 = 0$$

模型	实际 Top-1 项结构（系数待估）	结构	PINN
EqGPT	$c_1 u_x \sin x + c_2 u_t + c_3 u_x = 0$	错误	完成
AST-BPE	$c_1 u^2 + c_2 u_{xx} + c_3 u + c_4 u_t = 0$	错误	失败
Soft-AST-BPE	$c_1 u^2 + c_2 u_t + c_3 u_{xx} + c_4 u = 0$	错误	失败

Top-1 的最后系数记录（iteration 499）

$$\begin{aligned}
\text{GRE}: &\quad u_t - 82.12\, u_x \sin x + 58.97\, u_x = 0 \\
\text{AST}: &\quad u_t - 5.039\, u^2 - 1.334\, u_{xx} + 6.187\, u = 0 \\
\text{Soft}: &\quad u_t - 5.036\, u^2 - 1.338\, u_{xx} + 6.188\, u = 0
\end{aligned}$$